



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

POSGRADO EN CIENCIAS DE LA TIERRA

INSTITUTO DE CIENCIAS DE LA ATMÓSFERA Y CAMBIO CLIMÁTICO

Pronóstico Subestacional de la Oscilación Madden-Julian en las Américas Tropicales

T E S I S

que para optar por el grado de

MAESTRO EN CIENCIAS DE LA TIERRA

PRESENTA:

LUIS JESÚS OLVERA LAZCANO

Directora de Tesis:

DRA. CHRISTIAN DOMÍNGUEZ SARMIENTO

Instituto de Ciencias de la Atmósfera y Cambio Climático

Ciudad de México. Octubre 2024

Resumen

En los trópicos, el modo dominante de variabilidad de la escala subestacional es la Oscilación Madden-Julian (MJO, por sus siglas en inglés), que muestra una dependencia estacional, con una señal más fuerte durante el invierno boreal y un centro de convección inclinado latitudinalmente durante el verano boreal —denominada Oscilación Subestacional del Verano Boreal (BSISO, por sus siglas en inglés)—. Varios estudios han demostrado que ambos modos se pueden dividir en tipos. La MJO se divide en cuatro: estacionaria, rápida, lenta e intermitente; mientras que la BSISO se divide en: canónica, dipolo norte y expansión este. El presente estudio se enfoca en evaluar la habilidad de los distintos modelos del proyecto subestacional a estacional (S2S, por sus siglas en inglés) para simular las teleconexiones inducidas por los tipos de MJO y BSISO en las Américas tropicales. Se utilizó el reanálisis ERA5 para definir los distintos tipos durante el periodo 1980-2018. Posteriormente, se escogieron los modelos ECMWF, KMA, ECCC y IAP-CAS del proyecto S2S, utilizando las condiciones iniciales de los tipos de MJO y BSISO durante el periodo 2002-2017. La verificación de los modelos se realizó utilizando el Coeficiente de Correlación de Anomalías (ACC) y el índice Cuadrático Promedio de Habilidad (MSSS) para medir la habilidad potencial y la habilidad, respectivamente. Los resultados de los compuestos muestran que la señal convectiva de la MJO (invierno) no se presenta en las Américas tropicales, aunque sí se encuentra una señal de la precipitación. Las anomalías de temperaturas superficiales del mar muestran diferencias según el tipo de MJO y BSISO que se analiza. Por otro lado, la verificación muestra que los modelos ECMWF y KMA presentan una mejor habilidad para simular los patrones atmosféricos de los tipos de MJO y BSISO. En particular, la MJO lenta y la BSISO dipolo norte están mejor representados por los modelos, alcanzando en algunas variables una habilidad potencial mayor a 0.4 en las semanas 4 y 5. Lo anterior puede deberse a que los modelos representan con mejor habilidad las anomalías intra-estacionales de vientos troposféricos de menor magnitud, en comparación que aquellos tipos con anomalías de magnitud más grande (MJO rápida, estacionaria; BSISO canónica). Sin embargo, las anomalías de vientos a 10 m fueron representados con limitaciones. Estos resultados destacan la importancia de estudiar la escala subestacional en las Américas tropicales, principalmente en México, y la dinámica de la MJO y BSISO más allá de su centro de convección.

Índice general

Agradecimientos	I
Resumen	IV
1 Introducción	1
§1.1 La Oscilación Madden-Julian	1
§1.1.1 Dinámica de la MJO, teorías de su comportamiento y retroalimentación .	1
§1.1.2 Teorías sobre la iniciación de la MJO	2
§1.1.3 Tipos de MJO y BSISO	5
§1.2 Impactos de la MJO en México	8
§1.3 Pronóstico meteorológico y el pronóstico subestacional	11
§1.3.1 Pronóstico meteorológico	11
§1.3.2 Pronóstico subestacional	13
§1.4 Proyecto S2S: avances y limitaciones	14
§1.5 Avances en la modelación de la interacción océano-atmósfera de la MJO	17
§1.6 Planteamiento del problema	17
§1.7 Justificación	18
§1.8 Hipótesis	18
§1.9 Objetivos	19
§1.9.1 Objetivo general	19
§1.9.2 Objetivos específicos	19
§1.10 Estructura de la tesis	19
2 Datos y Métodos	21
§2.1 Reanálisis ERA5	21

§2.2	Índices de la MJO	23
§2.2.1	Índice RMM	23
§2.3	Descripción de los modelos climáticos de la base S2S	26
§2.3.1	ECMWF	27
§2.3.2	KMA	28
§2.3.3	ECCC	28
§2.3.4	IAP-CAS	29
§2.4	Definición de eventos MJO y BSISO	29
§2.4.1	Eventos MJO durante invierno	30
§2.4.2	Eventos BSISO durante verano	31
§2.5	Compuestos	32
§2.6	Métricas para evaluar los pronósticos subestacionales	33
§2.6.1	Correlación	34
§2.6.2	Correlación de Spearman	35
§2.6.3	Índice Cuadrático Promedio de Habilidad (MSSS, por sus siglas en inglés)	35
§2.7	Verificación Difusa	36
3	Resultados	38
§3.1	La diversidad de la MJO y la BSISO: su dinámica atmosférica y oceánica	38
§3.1.1	Características fundamentales de la MJO y BSISO	38
§3.1.2	Variabilidad de la precipitación durante eventos MJO y BSISO	45
§3.1.3	Variabilidad oceánica durante la MJO y BSISO	48
§3.1.4	Flujos de calor durante la MJO y BSISO	53
§3.2	Verificación semanal	59
§3.2.1	Correlación de Pearson	60
§3.2.2	MSSS	86
§3.3	Dinámica de los tipos de MJO y BSISO sobre México	105
§3.4	Predictibilidad en las dinámicas atmosféricas y oceánicas	110
4	Conclusiones y trabajo futuro	112
§4.1	Predictibilidad en los tipos de MJO y BSISO	112

§4.2 Limitaciones de los modelos para pronosticar la escala subestacional	113
§4.3 Trabajo futuro	114
Referencias	115
Anexo A Condiciones iniciales de los eventos MJO y BSISO	i
Anexo B Flujos de calor latente y sensible	iii
Anexo C Verificación semanal de las SST	iv
Anexo D Correlación de Spearman para la MJO lenta y la BSISO canónica	v
Anexo E Compuestos semanales de MJO y BSISO	vi

Índice de figuras

1.1	Descripción del comportamiento de la oscilación Madden-Julian	3
1.2	Media climatológica de las SST durante el verano e invierno boreal	6
1.3	Diagramas Hovmöller de compuestos de OLR (W/m^2) de los distintos tipos de MJO	7
1.4	Compuestos de OLR (W/m^2) de los distintos tipos de BSISO	8
1.5	Anomalías porcentuales de precipitación diaria (%) en las distintas fases de la MJO en el periodo 1982-2018	10
1.6	Anomalías estandarizadas de SST ($^{\circ}C$) (barra de color) y viento filtrado a 10 m (m/s) (vectores) en las distintas fases de la MJO en el periodo 1982-2018	11
2.1	Diagrama de espacio de fases del índice RMM	24
2.2	Estrategia de verificación difusa a partir del promedio de vecindades	37
3.1	Compuesto de los diagramas Hovmöller de la variable de OLR filtrada para los diferentes tipos de MJO según el análisis de clúster, realizados con un promedio zonal de $14^{\circ}N$ a $14^{\circ}S$	39
3.2	Compuestos en pentadas de anomalías de OLR filtradas (W/m^2) y viento a 850 mb (m/s) filtrado y estadísticamente significativo a 95 % de confianza para los tipos de MJO estacionaria y rápida.	40
3.3	Compuestos en pentadas de anomalías de OLR filtradas (W/m^2) y viento a 850 mb (m/s) filtrado y estadísticamente significativo a 95 % de confianza para los tipos de MJO lenta e intermitente	41
3.4	Igual que en la figura 3.2, pero con viento a 200mb filtrado y estadísticamente significativo a 95 % de confianza. El vector de referencia para el viento es de 5 m/s.	42

3.5	Igual que en la figura 3.3, pero con viento a 200 mb filtrado y estadísticamente significativo a 95 % de confianza. El vector de referencia para el viento es de 5 m/s.	42
3.6	Compuestos en pentadas de anomalías de OLR filtradas (W/m^2) y viento a 850 mb (m/s) filtrado y estadísticamente significativo a 95 % de confianza para los distintos tipos de BSISO.	44
3.7	Igual que en la figura 3.6, pero con viento a 200 mb (m/s) filtrado y estadísticamente significativo a 95 % de confianza. El vector de referencia para el viento es de 5 m/s.	44
3.8	Compuestos en pentadas de anomalías porcentuales de precipitación (%) para los tipos de MJO estacionaria y rápida. Las anomalías están calculadas con una media móvil de tres puntos zonales para eliminar el ruido de baja escala.	46
3.9	Compuestos en pentadas de anomalías porcentuales de precipitación (%) para los tipos de MJO lenta e intermitente. Las anomalías están calculadas con una media móvil de tres puntos zonales para eliminar el ruido de baja escala.	47
3.10	Compuestos en pentadas de anomalías porcentuales de precipitación (%) para los distintos tipos de BSISO. Las anomalías están calculadas con una media móvil de tres puntos zonales para eliminar el ruido de baja escala.	48
3.11	Compuestos en pentadas de anomalías estandarizadas de SST ($^{\circ}C$) y viento a 10 m (m/s) filtrado y estadísticamente significativo a 95 % de confianza en los tipos de MJO estacionaria y rápida. El vector de referencia indica 1 m/s.	49
3.12	Compuestos en pentadas de anomalías estandarizadas de SST ($^{\circ}C$) y viento a 10 m (m/s) filtrado y estadísticamente significativo a 95 % de confianza en los tipos de MJO lenta e intermitente. El vector de referencia indica 1 m/s.	50
3.13	Compuestos en pentadas de anomalías estandarizadas de SST ($^{\circ}C$) y viento a 10 m (m/s) filtrado y estadísticamente significativo a 95 % de confianza en los distintos tipos de BSISO. El vector de referencia indica 1 m/s.	52
3.14	Compuestos en pentadas de anomalías de flujo de calor latente (W/m^2) y viento a 10 m (m/s) filtrado y estadísticamente significativo a 95 % de confianza en los tipos de MJO estacionaria y rápida. El vector de referencia indica 1 m/s.	53

3.15	Compuestos en pentadas de anomalías de flujo de calor latente (W/m^2) y viento a 10 m (m/s) filtrado y estadísticamente significativo a 95 % de confianza en los tipos de MJO lenta e intermitente. El vector de referencia indica 1 m/s.	54
3.16	Compuestos en pentadas de anomalías de flujo de calor latente (W/m^2) y viento a 10 m (m/s) filtrado y estadísticamente significativo a 95 % de confianza en los distintos tipos de BSISO. El vector de referencia indica 1 m/s.	55
3.17	Compuestos en pentadas de anomalías de flujo de calor sensible (W/m^2) y viento a 10 m (m/s) filtrado y estadísticamente significativo en los tipos de MJO estacionaria y rápida. El vector de referencia indica 1 m/s.	57
3.18	Compuestos en pentadas de anomalías de flujo de calor sensible (W/m^2) y viento a 10 m (m/s) filtrado y estadísticamente significativo en los tipos de MJO lenta e intermitente. El vector de referencia indica 1 m/s.	58
3.19	Compuestos en pentadas de anomalías de flujo de calor sensible (W/m^2) y viento a 10 m (m/s) filtrado y estadísticamente significativo a 95 % de confianza en los distintos tipos de BSISO. El vector de referencia indica 1 m/s.	59
3.20	Coeficiente de correlación de Pearson de anomalías de OLR promedio sobre la región caja 120°W-86°W, 32°N-14°N en los diferentes tipos de MJO. Las líneas indican la evolución de la habilidad potencial de los 4 modelos.	61
3.21	Coeficiente de correlación de Pearson de anomalías de OLR de los modelos S2S con las observaciones durante la MJO estacionaria desde la semana 1 hasta la semana 5. Las regiones punteadas indican correlación estadísticamente significativa al 95 %. La línea continua indica las regiones donde la correlación es igual o mayor a 0.6.	61
3.22	Igual que en la figura 3.21, pero para la MJO rápida.	62
3.23	Igual que en la figura 3.21, pero para la MJO lenta.	62
3.24	Igual que en la figura 3.21, pero para la MJO intermitente.	63
3.25	Coeficiente de correlación de Pearson de anomalías de OLR promedio sobre la región caja 120°W-86°W, 32°N-14°N en los diferentes tipos de BSISO. Las líneas indican la evolución de la habilidad potencial de los 4 modelos.	64

3.26	Coeficiente de correlación de Pearson de anomalías de OLR de los modelos S2S con las observaciones durante la BSISO canónica desde la semana 1 hasta la semana 5. Las regiones punteadas indican correlación estadísticamente significativa al 95 %. La línea continua indica las regiones donde la correlación es igual o mayor a 0.6.	64
3.27	Igual que en la figura 3.26, pero para la BSISO dipolo norte.	65
3.28	Igual que en la figura 3.26, pero para la BSISO expansión este.	65
3.29	Coeficiente de correlación de Pearson de anomalías promedio de viento a 850 mb sobre la región caja 120°W-86°W, 32°N-14°N en los diferentes tipos de MJO. Las líneas indican la evolución de la habilidad potencial de los 4 modelos.	66
3.30	Coeficiente de correlación de Pearson de anomalías semanales de la magnitud del viento a 850 mb de los modelos S2S con las observaciones durante la MJO estacionaria. Las regiones punteadas indican correlación estadísticamente significativa al 95 %.	67
3.31	Igual que en la figura 3.30, pero para la MJO rápida.	67
3.32	Igual que en la figura 3.30, pero para la MJO lenta.	68
3.33	Igual que en la figura 3.30, pero para la MJO intermitente.	68
3.34	Coeficiente de correlación de Pearson de anomalías de viento a 850 mb promedio sobre la región caja 120°W-86°W, 32°N-14°N en los diferentes tipos de BSISO. Las líneas indican la evolución de la habilidad potencial de los 4 modelos.	69
3.35	Coeficiente de correlación de Pearson de anomalías semanales de la magnitud del viento a 850 mb de los modelos S2S con las observaciones durante la BSISO canónica. Las regiones punteadas indican correlación estadísticamente significativa al 95 %.	69
3.36	Igual que en la figura 3.35, pero para la BSISO dipolo norte.	70
3.37	Igual que en la figura 3.35, pero para la BSISO expansión este.	70
3.38	Coeficiente de correlación de Pearson de anomalías de viento a 200 mb promedio sobre la región 120°W-86°W, 32°N-14°N en los diferentes tipos de MJO. Las líneas indican la evolución de la habilidad potencial de los 4 modelos.	71

3.39	Coeficiente de correlación de Pearson de anomalías semanales de la magnitud del viento a 200 mb de los modelos S2S con las observaciones durante la MJO estacionaria. Las regiones punteadas indican correlación estadísticamente significativa al 95 %.	72
3.40	Igual que en la figura 3.39, pero para la MJO rápida.	72
3.41	Igual que en la figura 3.39, pero para la MJO lenta.	73
3.42	Igual que en la figura 3.39, pero para la MJO intermitente.	73
3.43	Coeficiente de correlación de Pearson de anomalías de viento a 200 mb promedio sobre la región 120°W-86°W, 32°N-14°N en los diferentes tipos de BSISO. Las líneas indican la evolución de la habilidad potencial de los 4 modelos.	74
3.44	Coeficiente de correlación de Pearson de anomalías semanales de la magnitud del viento a 200 mb de los modelos S2S con las observaciones durante la BSISO canónica. Las regiones punteadas indican correlación estadísticamente significativa al 95 %.	74
3.45	Igual que en la figura 3.44, pero para la BSISO dipolo norte.	75
3.46	Igual que en la figura 3.44, pero para la BSISO expansión este.	75
3.47	Coeficiente de correlación de Pearson de anomalías semanales de precipitación acumulada promediadas sobre la región 120°W-86°W, 32°N-14°N en los diferentes tipos de MJO. Las líneas indican la evolución de la habilidad potencial de los 4 modelos.	76
3.48	Coeficiente de correlación de Pearson de anomalías semanales de la precipitación acumulada de los modelos S2S con las observaciones durante la MJO estacionaria. Las regiones punteadas indican correlación estadísticamente significativa al 95 %.	77
3.49	Igual que en la figura 3.48, pero para la MJO rápida.	77
3.50	Igual que en la figura 3.48, pero para la MJO lenta.	78
3.51	Igual que en la figura 3.48, pero para la MJO intermitente.	78
3.52	Coeficiente de correlación de Pearson de anomalías semanales de precipitación acumulada promediadas sobre la región 120°W-86°W, 32°N-14°N en los diferentes tipos de BSISO. Las líneas indican la evolución de la habilidad potencial de los 4 modelos.	79

3.53	Coeficiente de correlación de Pearson precipitación acumulada semanal de los modelos S2S con las observaciones durante la BSISO canónica. Las regiones punteadas indican correlación estadísticamente significativa al 95 %.	80
3.54	Igual que en la figura 3.53, pero para la BSISO dipolo norte.	80
3.55	Igual que en la figura 3.53, pero para la BSISO expansión este.	81
3.56	Coeficiente de correlación de Pearson de anomalías semanales de viento a 10 m sobre la región 120°W-86°W, 32°N-14°N en los diferentes tipos de MJO. Las líneas indican la evolución de la habilidad potencial de los 4 modelos.	81
3.57	Coeficiente de correlación de Pearson de las anomalías semanales de la magnitud del viento a 10 m de los modelos S2S con las observaciones durante la MJO estacionaria. Las regiones punteadas indican correlación estadísticamente significativa al 95 %.	82
3.58	Igual que en la figura 3.57, pero para la MJO rápida.	83
3.59	Igual que en la figura 3.57, pero para la MJO lenta.	83
3.60	Igual que en la figura 3.57, pero para la MJO intermitente.	84
3.61	Coeficiente de correlación de Pearson de anomalías semanales de anomalías semanales de viento a 10 m la región 120°W-86°W, 32°N-14°N en los diferentes tipos de BSISO. Las líneas indican la evolución de la habilidad potencial de los 4 modelos.	84
3.62	Coeficiente de correlación de Pearson de anomalías semanales de la magnitud del viento a 10 m de los modelos S2S con las observaciones durante la BSISO canónica. Las regiones punteadas indican correlación estadísticamente significativa al 95 %.	85
3.63	Igual que la figura 3.62, pero para la BSISO dipolo norte.	85
3.64	Igual que en la figura 3.62, pero para la BSISO expansión este.	86
3.65	Mean Square Skill Score de anomalías semanales promedio de OLR de los modelos S2S durante la MJO estacionaria. Las regiones punteadas indican puntajes mayores a 0.	87
3.66	Igual que en la figura 3.65, pero para la MJO rápida.	87
3.67	Igual que en la figura 3.65, pero para la MJO lento.	88
3.68	Igual que en la figura 3.65, pero para la MJO intermitente.	88

3.69	Mean Square Skill Score de anomalías semanales promedio de OLR de los modelos S2S durante la BSISO canónica. Las regiones punteadas indican puntajes mayores a 0.	89
3.70	Igual que en la figura 3.69 pero para la BSISO dipolo norte.	89
3.71	Igual que en la figura 3.69 pero para la BSISO expansión este.	90
3.72	Mean Square Skill Score de anomalías semanales promedio de la magnitud del viento a 850 mb de los modelos S2S durante la MJO estacionaria. Las regiones punteadas indican puntajes mayores a 0.	91
3.73	Igual que en la figura 3.72 pero para la MJO rápida.	91
3.74	Igual que en la figura 3.72 pero para la MJO lenta.	92
3.75	Igual que en la figura 3.72 pero para la MJO intermitente.	92
3.76	Mean Square Skill Score (MSSS) de anomalías semanales promedio de la magnitud del viento a 850 mb de los modelos S2S durante la BSISO canónica. Las regiones punteadas indican puntajes mayores a 0.	93
3.77	Igual que en la figura 3.76 pero para la BSISO dipolo norte.	93
3.78	Igual que en la figura 3.76 pero para la BSISO expansión este.	94
3.79	Mean Square Skill Score de anomalías semanales promedio de la magnitud del viento a 200 mb de los modelos S2S durante la MJO estacionaria. Las regiones punteadas indican puntajes mayores a 0.	94
3.80	Igual que en la figura 3.79 pero para la MJO rápida.	95
3.81	Igual que en la figura 3.79 pero para la MJO lenta.	95
3.82	Igual que en la figura 3.79 pero para la MJO intermitente.	96
3.83	Mean Square Skill Score de anomalías semanales promedio de la magnitud del viento a 200 mb de los modelos S2S durante la BSISO canónica. Las regiones punteadas indican puntajes mayores a 0.	96
3.84	Igual que en la figura 3.83 pero para la BSISO dipolo norte.	97
3.85	Igual que en la figura 3.83 pero para la BSISO expansión este.	97
3.86	Mean Square Skill Score del acumulado semanal de precipitación en los modelos S2S durante la MJO estacionaria. Las regiones punteadas indican puntajes mayores a 0.	98
3.87	Igual que en la figura 3.86 pero para la MJO rápida.	99

3.88	Igual que en la figura 3.86 pero para la MJO lenta.	99
3.89	Igual que en la figura 3.89 pero para la MJO intermitente.	100
3.90	Mean Square Skill Score de anomalías del acumulado semanal de precipitación de los modelos S2S durante la BSISO canónica. Las regiones punteadas indican puntajes mayores a 0.	100
3.91	Igual que en la figura 3.90 pero para la BSISO dipolo norte.	101
3.92	Igual que en la figura 3.90 pero para la BSISO expansión este.	101
3.93	Mean Square Skill Score de anomalías semanales promedio de la magnitud del viento a 10 m de los modelos S2S durante la MJO estacionaria. Las regiones punteadas indican puntajes mayores a 0.	102
3.94	Igual que en la figura 3.93 pero para la MJO rápida.	102
3.95	Igual que en la figura 3.93 pero para la MJO lenta.	103
3.96	Igual que en la figura 3.93 pero para la MJO intermitente.	103
3.97	Mean Square Skill Score de anomalías semanales promedio de la magnitud del viento a 10 m de los modelos S2S durante la BSISO canónica. Las regiones punteadas indican puntajes mayores a 0.	104
3.98	Igual que en la figura 3.97, pero para la BSISO dipolo norte.	104
3.99	Igual que en la figura 3.97, pero para la BSISO expansión este.	105
3.100	Número de casos por mes de las CIs en el periodo 1980-2018.	109
3.101	Gráficas de caja y bigotes de la amplitud de los tipos de MJO y BSISO de acuerdo con 4 tipos de índice.	109
B.1	Promedio diario de a) flujo de calor latente y b) flujo de calor sensible durante el invierno boreal.	iii
B.2	Promedio diario de a) flujo de calor latente y b) flujo de calor sensible durante el verano boreal.	iii
C.1	Coeficiente de correlación de Pearson de anomalías semanales de las SST de los modelos S2S con las observaciones durante la BSISO canónica. Las regiones punteadas indican correlación estadísticamente significativa al 95 %.	iv

C.2	Mean Square Skill Score de anomalías semanales promedio de las SST de los modelos S2S durante la BSISO canónica. Las regiones punteadas indican puntajes mayores a 0.	iv
D.1	Coeficiente de correlación de Spearman de anomalías de OLR de los modelos S2S con las observaciones durante la MJO lenta desde la semana 1 hasta la semana 5. Las regiones punteadas indican correlación estadísticamente significativa al 95 %. La línea continua indica las regiones donde la correlación es igual o mayor a 0.6.	v
D.2	Coeficiente de correlación de Spearman de anomalías de OLR de los modelos S2S con las observaciones durante la BSISO dipolo norte desde la semana 1 hasta la semana 5. Las regiones punteadas indican correlación estadísticamente significativa al 95 %. La línea continua indica las regiones donde la correlación es igual o mayor a 0.6.	v
E.1	Compuestos semanales de anomalías de OLR filtradas (W/m^2) y viento a 850 mb (m/s) filtrado y estadísticamente significativo a 95 % de confianza para los tipos de MJO estacionaria y rápida. El contorno continuo (discontinuo) indica anomalías menores (mayores) a $-5 W/m^2$ ($5 W/m^2$). El vector de referencia para el viento es de 2 m/s. Las anomalías están calculadas con una media móvil de tres puntos zonales para eliminar el ruido de menor escala.	vi
E.2	Compuestos semanales de anomalías de OLR filtradas (W/m^2) y viento a 850 mb (m/s) filtrado y estadísticamente significativo a 95 % de confianza para los tipos de MJO lenta y estacionaria. El contorno continuo (discontinuo) indica anomalías menores (mayores) a $-5 W/m^2$ ($5 W/m^2$). El vector de referencia para el viento es de 2 m/s. Las anomalías están calculadas con una media móvil de tres puntos zonales para eliminar el ruido de menor escala.	vii
E.3	Igual que en la figura E.1, pero con viento a 200 mb filtrado y estadísticamente significativo a 95 % de confianza. El vector de referencia para el viento es de 5 m/s.	vii
E.4	Igual que en la figura E.2, pero con viento a 200 mb filtrado y estadísticamente significativo a 95 % de confianza. El vector de referencia para el viento es de 5 m/s.	viii

E.5	Compuestos semanales de anomalías de OLR filtradas (W/m^2) y viento a 850 mb (m/s) filtrado y estadísticamente significativo a 95 % de confianza para los distintos tipos de BSISO. El contorno continuo (discontinuo) indica anomalías menores (mayores) a $-5 W/m^2$ ($5 W/m^2$). El vector de referencia para el viento es de 2 m/s. Las anomalías están calculadas con una media móvil de tres puntos zonales para eliminar el ruido de baja escala.	viii
E.6	Compuestos semanales de anomalías porcentuales de precipitación (%) para los tipos de MJO estacionaria y rápida. Las anomalías están calculadas con una media móvil de tres puntos zonales para eliminar el ruido de baja escala. Los puntos indican valores estadísticamente significativos al 95 % de intervalo de confianza.	ix
E.7	Compuestos semanales de anomalías porcentuales de precipitación (%) para los tipos de MJO lenta e intermitente. Las anomalías están calculadas con una media móvil de tres puntos zonales para eliminar el ruido de baja escala. Los puntos indican valores estadísticamente significativos al 95 % de intervalo de confianza. .	ix
E.8	Igual que en la figura E.5, pero con viento a 200 mb filtrado y estadísticamente significativo a 95 % de confianza. El vector de referencia para el viento es de 5 m/s.	x
E.9	Compuestos semanales de anomalías porcentuales de precipitación (%) para los distintos tipos de BSISO. Las anomalías están calculadas con una media móvil de tres puntos zonales para eliminar el ruido de baja escala. Los puntos indican valores estadísticamente significativos al 95 % de intervalo de confianza.	x

Índice de tablas

1.1	Características principales de los sistemas hindcast del PS2S.	15
A.1	Fechas de inicio de los diferentes tipos de MJO obtenidas en el análisis de clúster. El periodo 2002-2017 corresponde a las CIs utilizadas en la verificación.	i
A.2	Fechas de inicio de los diferentes tipos de BSISO obtenidas en el análisis de clúster. El periodo 2002-2017 corresponde a las CIs utilizadas en la verificación.	ii
A.3	Tabla de años con condiciones de El Niño, La Niña o Neutro (basado en el ONI) en las CIs de los tipos de MJO y BSISO del periodo 1980-2018.	ii
A.4	Tabla de años con condiciones de El Niño, La Niña o Neutro (basado en el ONI) en las CIs de los tipos de MJO y BSISO usadas para la verificación (periodo 2002-2017).	ii

Capítulo 1

Introducción

1.1. La Oscilación Madden-Julian

1.1.1. Dinámica de la MJO, teorías de su comportamiento y retroalimentación

El planeta Tierra está conformado por la litósfera, criósfera, biósfera, hidrósfera y atmósfera, las cuales se interconectan a través del sistema climático. Los procesos que ocurren en la atmósfera tienen diversas dinámicas y escalas espaciotemporales ([Peixoto & Oort, 1992](#)). Aquellos que varían desde segundos hasta días se encuentran en el rango del tiempo meteorológico. Por su parte, los procesos que varían en escala de meses, años o décadas corresponden al clima, que se cuantifica con registros de 20 a 30 años aproximadamente. Por otro lado, los modos de variabilidad climática natural son oscilaciones que dependen del acoplamiento entre el océano y la atmósfera para mantenerse y evolucionar en los trópicos ([Vitart & Robertson, 2019](#)). Los modos de variabilidad dominantes en los trópicos son El Niño Oscilación del Sur (ENSO, por sus siglas en inglés) en la escala interanual y la MJO en la escala intraestacional —también conocida como subestacional—. De acuerdo con [Moron et al. \(2019\)](#), la escala subestacional es denominada como “el tiempo dentro del clima”, ya que los diferentes estados del tiempo meteorológico conducen a modulaciones climáticas.

La MJO puede ser definida como un fenómeno atmosférico con propagación hacia el este, conformado por un centro de convección intensificado (fase de intensificación) que comienza en

el océano Índico ecuatorial y una zona de supresión hacia el oeste de la convección (fase de supresión). Su centro convectivo desaparece a la mitad del Pacífico ecuatorial, pero su señal continúa propagándose más allá del Golfo de México y Mar Caribe (Knutson & Weickmann, 1987; Slingo et al., 1996). La MJO tiene una duración total aproximada de 20 a 100 días (Knutson & Weickmann, 1987; Madden & Julian, 1972; Slingo et al., 1996; Woolnough, 2019). El nombre de esta oscilación se debe a sus descubridores, Roland Madden y Paul Julian, quienes hicieron un diagrama del proceso de desplazamiento de la oscilación (Figura 1.1). Debido a que la oscilación comprende un conjunto de perturbaciones en la estructura del viento y en los patrones de convección tropical, se identifica y monitorea principalmente a través de anomalías de viento y de radiación de onda larga (OLR, por sus siglas en inglés) (Madden & Julian, 1972; C. Zhang, 2013).

La intensidad de la MJO es mayor durante el invierno boreal que durante el verano, razón por la cual los estudios separan sus efectos dependiendo de la estación que se considera. Los estudios que consideran sólo el verano suelen nombrar a la MJO como la Oscilación Intraestacional del Verano Boreal, BSISO (Woolnough, 2019). En el presente estudio se consideran ambos eventos. Las secciones posteriores del capítulo explican la dinámica de acuerdo con la estacionalidad de la MJO.

1.1.2. Teorías sobre la iniciación de la MJO

La evolución de la MJO ocasiona calentamiento en la atmósfera y en el océano como consecuencia de la convección profunda que se desarrolla en el océano Índico y el océano Pacífico Oeste. Su evolución y desplazamiento involucra la génesis de ondas de Rossby tropicales —ligadas al desarrollo de anticiclones y ciclones en la alta tropósfera— hacia el oeste y este del centro de la convección (Hendon & Salby, 1994; Sperber, 2003; Woolnough, 2019). Adicionalmente, Z. Li et al. (2018) enfatizan que los pares de anticiclones y ciclones adyacentes al centro de convección también inducen ondas de Kelvin, considerando que la MJO es un acoplamiento de ondas Kelvin y Rossby, como sugirieron inicialmente B. Wang (1988) y B. Wang y Li (1994).

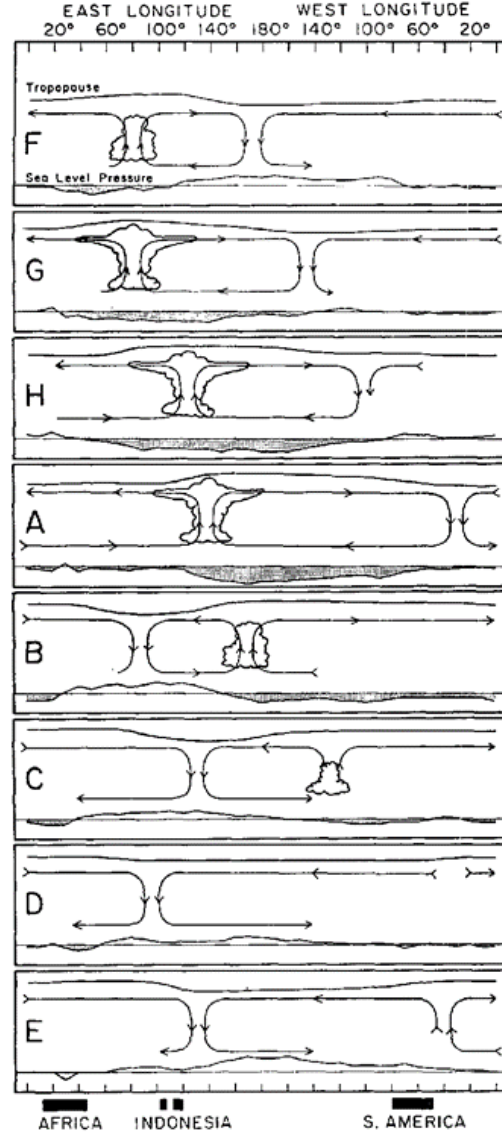


Figura 1.1. Diagrama esquemático del desarrollo de la MJO. En el eje vertical, se presenta la altura desde el nivel del mar hasta la tropopausa. El eje horizontal representa la longitud. Los vectores representan las anomalías de viento que convergen y divergen de acuerdo con el centro de convección. Tomado de ([Madden & Julian, 1972](#))

A lo largo de los años han surgido varios conjuntos de teorías que buscan explicar los mecanismos de iniciación de la MJO. Estos tienen como objetivo primordial tener una mejor aproximación de la dinámica de la MJO para producir mejores modelos que sean capaces de simular su evolución y posteriormente, generar mejores pronósticos. Recientemente, [Lin \(2022\)](#) hizo una revisión completa sobre las principales teorías de sus mecanismos de formación. El primer grupo de teorías se conoce como el de la interacción triple, que consiste en una actualización de la teoría original del acoplamiento de ondas de Kelvin-Rossby ([B. Wang, 1988](#);

B. Wang, Liu, & Chen, 2016), pero considerando una conexión entre la convergencia, la capa límite planetaria (PBL, por sus siglas en inglés) y la humedad, los cuales son factores cruciales en la formación de la estructura Kelvin-Rossby.

El segundo grupo de teorías se denomina modos de humedad. Como su nombre indica, este considera que la humedad es uno de los factores más importantes para la iniciación de la convección (Raymond, 2001). Las teorías se describen mediante: a) la aproximación del gradiente de temperatura débil (WTG, por sus siglas en inglés; Sobel et al., 2001), que fue propuesta para explicar la oscilación Sobel y Maloney (2012) y modificada posteriormente por Adames y Kim (2016), y b) la importancia del intercambio de calor superficial inducido por el viento (WISHE, por sus siglas en inglés, por Emanuel, 1986) propuesta por Fuchs y Raymond (2005). La teoría WTG utiliza la columna de humedad como única variable del pronóstico de la evolución de la MJO y su movimiento vertical está en balance con el calentamiento diabático. Por otro lado, la teoría WISHE utiliza la ecuación termodinámica y la ecuación de momento, haciendo que el intercambio de calor sea el factor fundamental que detona la inestabilidad de humedad en la MJO (Fuchs & Raymond, 2017).

El tercer grupo se refiere al “esqueleto” de la MJO. Estas teorías están enfocadas principalmente en la actividad de las ondas; es decir, se centra en la dinámica de la oscilación: velocidad de fase, relación de dispersión; así como su estructura cuadripolar (pares de anticiclones y ciclones) (Majda & Stechmann, 2009; Stechmann & Majda, 2015).

Por su parte, el cuarto grupo de teorías considera a la MJO como un grupo de ondas de inercio-gravedad que se propagan hacia el oeste y hacia el este (Westward Inertial-Gravity wave, WIG y, Eastward Inertial-Gravity wave, EIG; por sus siglas en inglés), y que al tener una gran velocidad de propagación pueden inducir la iniciación de la MJO en términos de viento (Yang & Ingersoll, 2014). Sin embargo, este grupo de teorías no pueden explicar los mecanismos de iniciación de la convección.

Finalmente, el quinto grupo de teorías sugiere que la MJO se detona a partir de la propagación de pares de vórtices ubicados al oeste de la oscilación (i.e., previo a que se inicie su centro convectivo), ya sea debido a la propagación de una onda de Rossby relacionada con

la advección no-lineal de la vorticidad potencial (Yano & Tribbia, 2017), o bien debido a la propagación de un par de ciclones relacionados con el “estiramiento” de la vorticidad potencial planetaria asociada a la convección (Hayashi & Itoh, 2017).

Además de teorías particulares, S. Wang y Sobel (2022), sugieren que el gradiente meridional de la humedad es un componente fundamental para la formación de la estructura característica de la MJO y su contraparte del verano boreal (ver sección 1.1.3).

Como se ha mencionado hasta ahora, los grupos de teorías de la MJO proponen diversos mecanismos dinámicos. Sin embargo, la mayoría consideran que la humedad y el calentamiento diabático (convección) juegan un papel fundamental en la evolución de la MJO. De acuerdo con Woolnough (2019), una teoría ideal de la MJO debería tomar en cuenta la liberación de calor latente asociado a la convección, las anomalías de los flujos superficiales y radiativos, así como su evolución al interactuar con los flujos de gran escala.

La iniciación y evolución de la MJO pueden depender fuertemente de las condiciones climáticas previas a su formación y a su interacción con las distintas esferas del sistema climático, específicamente con el océano (Vitart & Robertson, 2019). La MJO también se puede relacionar con el hielo marino y las oscilaciones estratosféricas, como la oscilación cuasi-bienal (QBO, por sus siglas en inglés) (Lee & Seo, 2019; Back et al., 2020). Sin embargo, el presente trabajo sólo se enfocará en las interacciones de la atmósfera con el océano una vez que está formada la MJO.

1.1.3. Tipos de MJO y BSISO

Kikuchi (2021) hace una revisión exhaustiva sobre la BSISO, partiendo de las diferencias entre las condiciones de frontera –definidas por las temperaturas superficiales del mar (SST, por sus siglas en inglés)— que existen entre el verano e invierno boreal (Figura 1.2).

Los eventos de la MJO y BSISO que se forman y se desplazan hacia el este no tienen el mismo comportamiento en términos de su velocidad de propagación, su movimiento y estructura. Por ejemplo, Seo y Kumar (2008) afirman que los eventos MJO más intensos (i.e. con anomalías de OLR de mayor magnitud) tienen una velocidad de propagación menor en comparación con otras MJOs. Kim et al. (2014) mencionan la existencia de eventos MJO propagados y no

propagados según la fuerza de la anomalía seca (valores positivos de OLR) sobre el continente marítimo. Por su parte, [B. Wang et al. \(2019\)](#) realizaron un análisis de anomalías de OLR filtradas de 20 a 70 días en el océano Índico durante el invierno del periodo de 1979-2013 y descubrieron que la MJO tiene 4 tipos de comportamiento: rápido, lento, intermitente y estacionario (Figura 1.3). De acuerdo con [B. Wang et al. \(2019\)](#), las MJO estacionarias no se propagan hacia el este, se mantienen donde surgieron. Las MJOs intermitentes se caracterizan por presentar anomalías simultáneas en el centro de la convección principal. Las MJOs rápidas y lentas se caracterizan por una mayor y menor velocidad de propagación, respectivamente. Por su parte, las MJOs lentas tienen mayor predictibilidad que las MJOs estacionarias y las MJOs intermitentes ([Chen, 2021](#); [B. Wang et al., 2019](#)). Lo anterior es debido a que las MJOs lentas dependen del calentamiento diabático, mientras que las MJOs estacionarias o intermitentes están caracterizadas por dinámicas no-lineales que usualmente los modelos no replican ([Chen, 2021](#)).




Figura 1.2. Media climatológica de las SST ($^{\circ}\text{C}$) durante: a) verano boreal y b) invierno boreal, utilizando la base de datos interpolados de SST de la NOAA. Tomado de [Kikuchi \(2021\)](#).

Una posible explicación sobre la diversidad en el comportamiento de la MJO se relaciona con las variaciones en los patrones del calentamiento tropical, así como a las variaciones en el flujo medio ([Chen, 2021](#); [DeMott et al., 2019](#)). Los eventos MJO que muestran una propagación están asociadas con una respuesta fuerte de las ondas de Kelvin, mientras que las MJOs estacionarias tiene una relación débil con este tipo de ondas. Adicionalmente, también existen variaciones espaciales en la ocurrencia de la MJO. [Matthews \(2008\)](#) explica que existen 2 tipos de MJO de acuerdo con su iniciación: la MJO primaria (aquella que no proviene de ninguna MJO previa) y la MJO secundaria (aquella que tiene una predecesora y regresa al punto donde inicio su centro convectivo). El 40 % de los eventos de la MJO comienzan con el centro de la convección localizado sobre el océano Índico o el Continente Marítimo, ya que su amplitud es mayor a 1 (basado en el índice RMM, ver sección 2.2) ([Wu et al., 2023](#)). Asimismo, algunos eventos de la

MJO tienden a desaparecer antes de llegar al centro del océano Pacífico tropical (Woolnough, 2019).

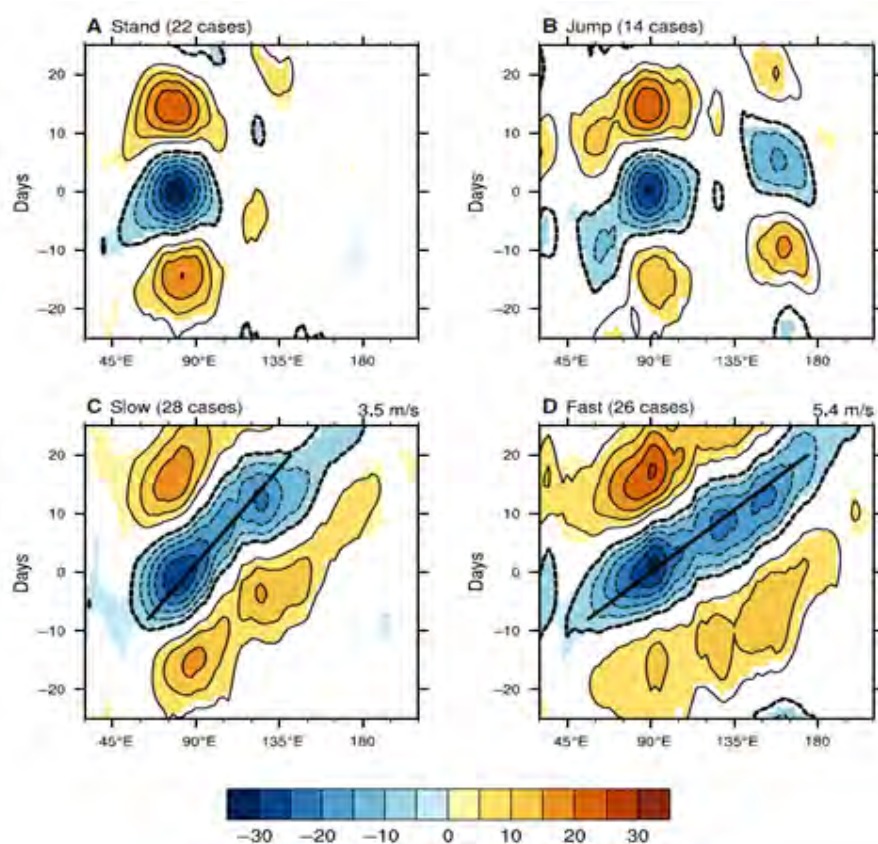


Figura 1.3. Diagramas Hovmöller de compuestos de OLR (W/m^2) de los distintos tipos de MJO, durante el invierno boreal (nov-abril) en el periodo 1979-2013 y franja 10°N - 10°S . a) MJO estacionaria, b) MJO intermitente, c) MJO lenta, d) MJO rápida. Tomado de B. Wang et al. (2019).

De manera análoga, Chen y Wang (2021) analizaron la BSISO a partir de datos de OLR filtrados y análisis de clúster, develando la existencia de eventos BSISO que no solamente se propagan hacia el noreste, sino que conforman un dipolo hacia el norte y una expansión hacia el este (Figura 1.4). Así, durante verano se forman tres tipos de BSISO: canónica, dipolo norte y expansión este. La primera refiere al comportamiento conocido de la BSISO durante el verano; mientras que el caso dipolo norte es caracterizado por la generación de cuatro centros alternados de supresión e intensificación de la nubosidad (Figura 1.4). Asimismo, el tipo expansión este denota poca actividad de inhibición de la convección y un área de intensificación extendida sobre la franja tropical.

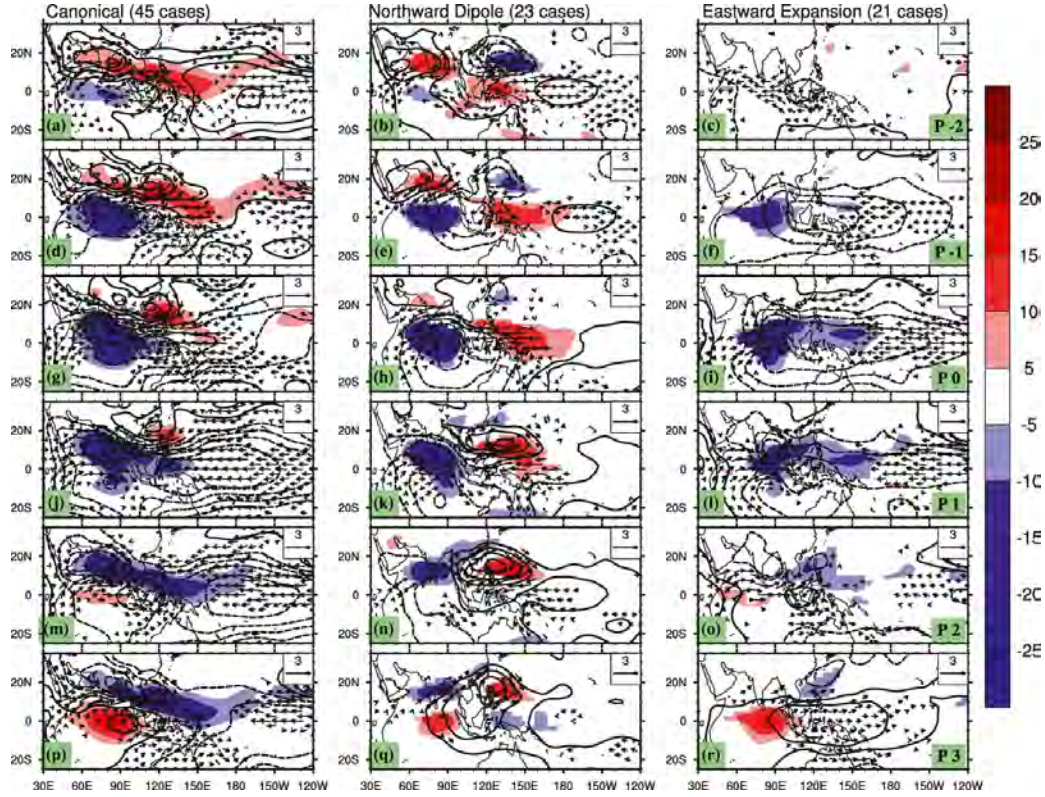


Figura 1.4. *Compuestos de OLR (W/m^2) de los distintos tipos de BSISO, durante el verano boreal (may-oct) en el periodo 1979-2016 y franja $10^\circ N$ - $10^\circ S$. Tomado de [Chen y Wang \(2021\)](#).*

1.2. Impactos de la MJO en México

Aunque la MJO tiene características diferentes de acuerdo con la estacionalidad, la mayor parte de los estudios la analizan de forma indistinta. Por lo anterior, en esta sección se mencionan los efectos tanto de la MJO como de la BSISO, tomando por nombre general la MJO. Esta tiene efectos que prevalecen más allá de su centro de convección ([C. Zhang, 2013](#)). Las ondas inducidas por el desplazamiento de la MJO viajan a través de la circulación de gran escala, produciendo teleconexiones desde los trópicos hasta los extratrópicos por medio de ondas de Rossby ([Jin & Hoskins, 1995](#); [Lin et al., 2019](#); [Wallace & Gutzler, 1981](#)). Sin embargo, es importante mencionar que la interacción trópicos-extratrópicos es un proceso bidireccional; es decir, los procesos que ocurren en los trópicos pueden modificar los procesos que ocurren en los extratrópicos y viceversa ([Laing & Evans, 2016](#)), como la influencia de ondas extratropicales sobre la convección tropical ([Lin et al., 2019](#); [Matthews & Kiladis, 1999](#)).

La temperatura y la precipitación son variables que pueden ser modificadas por la MJO, incluso sus extremos, definidos por los percentiles del 90 %, 95 % o 99 % (Vitart et al., 2019). La modulación de estas variables puede ser expresada en términos de las teleconexiones que tiene la MJO en los fenómenos meteorológicos y climáticos que producen o inhiben la lluvia en México. Los fenómenos meteorológicos que afectan a México durante verano son los ciclones tropicales, las ondas del este, los sistemas convectivos de mesoescala asociados (Ramos-Pérez et al., 2022), la Zona de Convergencia Intertropical (ZCIT) y los fenómenos climáticos son el Monzón de Norteamérica (NAM, por sus siglas en inglés) (Adams & Comrie, 1997), la corriente en chorro de bajos niveles del Caribe (Magaña et al., 1999; C. Wang, 2007) la sequía de medio verano (MSD, por sus siglas en inglés) (Magaña et al., 1999). Diversos estudios sugieren que la MJO es capaz de influenciar dichos fenómenos (D. J. Lorenz & Hartmann, 2006; C. Zhang, 2013). Por ejemplo, Perdigón-Morales et al. (2021) analizaron la relación de la MJO con la MSD y descubrieron que las fases 1 y 2 de la MJO aumentan el aporte de humedad en el suroeste del país durante el primer pico de lluvias, modificando así el transporte de humedad de la Corriente en Chorro de Bajos Niveles del Caribe (CLLJ, por sus siglas en inglés). Zhao et al. (2023) obtuvieron resultados similares en los patrones climatológicos de la MSD, concordando con Perdigón-Morales et al. (2021).

Por otro lado, Olvera-Lazcano (2022) encontró que, durante el verano boreal, la MJO modifica los patrones de precipitación extrema en el país, así como la extensión de la alberca de agua caliente del hemisferio occidental. Además, este estudio analizó el efecto acoplado de la MJO bajo condiciones del ENSO (Figuras 1.5; 1.6). Olvera-Lazcano (2022) clasifica en 2 fases principales a la MJO: la fase húmeda (fases 8, 1 y 2) y fase seca (fases 3 a 7). La fase húmeda está caracterizada por un aumento en la precipitación sobre las costas del Pacífico mexicano, un aumento en la ocurrencia de eventos extremos de precipitación en las regiones centrales del país, así como una disminución de las SST y una dominancia de vientos del oeste en la costa occidental de México. Asimismo, la fase seca exhibe una inhibición importante de la precipitación sobre gran parte del país, particularmente sobre la costa occidental y favorece el calentamiento en las aguas del océano Pacífico mexicano. Este calentamiento comienza en la franja ecuatorial y se concentra en las costas mexicanas (Olvera-Lazcano, 2022).

Los vientos del oeste asociados al desplazamiento de la MJO inducen perturbaciones oceánicas, las cuales pueden prevalecer durante varios días (DeMott et al., 2015); simultáneamente, la variabilidad de las SST está relacionada con la ocurrencia de eventos extremos de precipitación (i.e., eventos de precipitación que son mayores al percentil 95) en la región norte de México (H. Zhang, 2020). Esto puede indicar la existencia de una relación entre el viento, la SST y la precipitación asociada a la MJO. Sin embargo, aunque el aumento de la precipitación se relaciona con un aumento en las SST —que a su vez modifican el flujo de calor latente y la convección—, Roxy (2013) menciona que existe un desfase entre el aumento de las SST y el aumento de la precipitación. Así que los resultados encontrados por Olvera-Lazcano (2022) necesitan más análisis considerando diferentes tiempos de retraso en la respuesta oceánica.

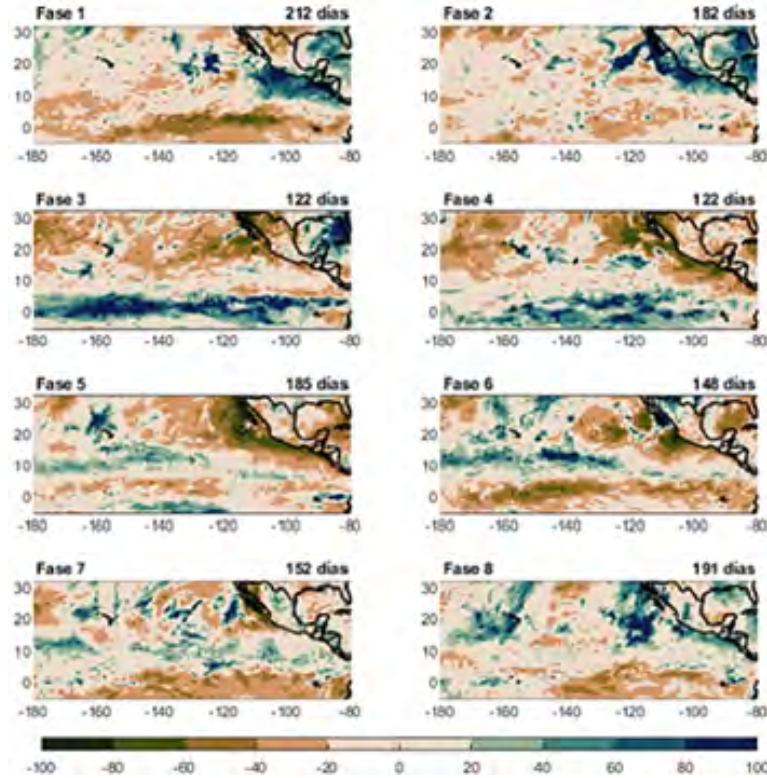


Figura 1.5. Anomalías porcentuales de precipitación diaria (%) en las distintas fases de la MJO en el periodo 1982-2018. Anomalías de -100 % indican ausencia total de precipitación. Tomado de Olvera-Lazcano (2022).

La información relacionada con la dinámica de la MJO y sus efectos en México es fundamental para desarrollar adecuados pronósticos subestacionales y, como meta final, aportar información para la creación de sistemas de alerta temprana eficientes.

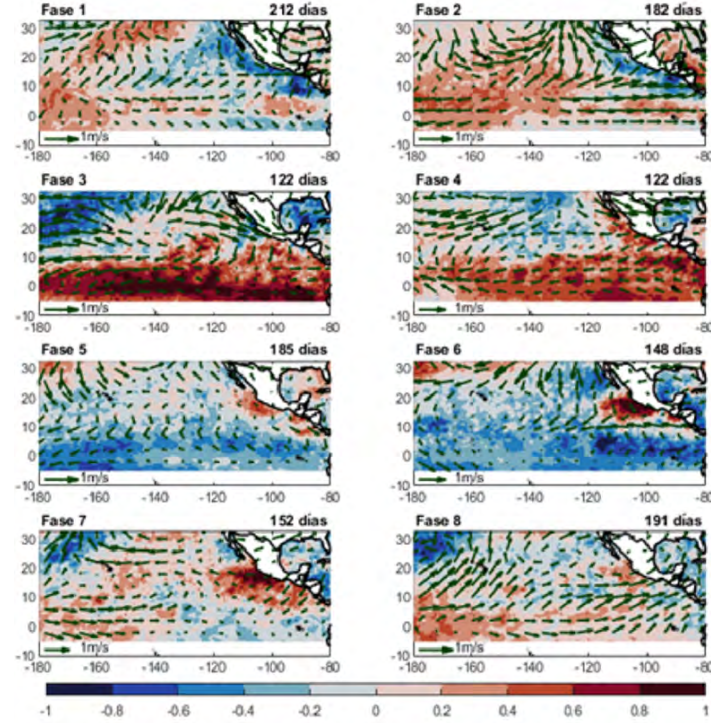


Figura 1.6. Anomalías estandarizadas de SST ($^{\circ}\text{C}$) (barra de color) y viento filtrado a 10 m (m/s) (vectores) en las distintas fases de la MJO en el periodo 1982-2018. Los vectores en la parte inferior de cada gráfica representan la escala de 1 m/s correspondiente a cada compuesto. Tomado de [Olvera-Lazcano \(2022\)](#).

1.3. Pronóstico meteorológico y el pronóstico subestacional

1.3.1. Pronóstico meteorológico

[Toth y Buizza \(2019\)](#) definen a la predictibilidad como la capacidad de predecir el estado futuro de las esferas del sistema climático. En la atmósfera, dicha evolución puede ser explicada a partir de las leyes físicas y ecuaciones que integran un modelo matemático, lo que la define como un sistema dinámico ([Palmer & Hagedorn, 2006](#)) y, por lo tanto, es posible predecir su comportamiento a partir de dichas leyes. Sin embargo, su predictibilidad tiene límites debido a que: 1) la atmósfera presenta inestabilidades que crecen con el tiempo; 2) existen procesos físicos que no están representados adecuadamente en las formulaciones numéricas y matemáticas de su dinámica ([Toth & Buizza, 2019](#)). De esta manera, la estimación exacta de los procesos físicos de la atmósfera es imposible, ya que está en continuo cambio ([Palmer & Hagedorn, 2006](#); [Toth & Buizza, 2019](#)). Dichos factores conforman el problema de la determinación de las condiciones iniciales (CIs), las cuales describen el estado de la atmósfera en un tiempo dado para la ejecu-

ción de un modelo de pronóstico. [E. N. Lorenz \(1963\)](#) descubrió que la evolución de las CIs la atmósfera es de carácter divergente –i.e. indican estados futuros fundamentalmente distintos– y, por lo tanto, determina que la atmósfera es un sistema caótico. Posteriormente, [E. N. Lorenz \(1969\)](#) encontró que las perturbaciones en las CIs crecen de forma exponencial en el tiempo, ocasionando la amplificación de errores dentro de las ecuaciones que describen el movimiento atmosférico y en consecuencia limitando la predictibilidad del pronóstico meteorológico. Estos errores e inestabilidades aumentan conforme la resolución espacial es mayor, debido a la dificultad de parametrizar los procesos físicos como la convección, ya que su evolución puede ocurrir en una escala espacial muy pequeña y una escala de tiempo muy corta ([Toth & Buizza, 2019](#)).

De esta forma, la habilidad de los modelos de pronóstico depende –además de la precisión de las CIs– de la representación de la topografía, la física del modelo –es decir, las ecuaciones que utilizan para representar los distintos procesos– y el método de resolución de la malla del modelo ([Vitart & Robertson, 2019](#)).

En la actualidad existen dos tipos de pronósticos meteorológicos: 1) los pronósticos determinísticos y 2) los pronósticos probabilísticos. Los pronósticos determinísticos se construyen a partir de la integración de un solo modelo atmosférico con una CI; es decir, se usa solamente un pronóstico que estima el estado futuro del sistema. Por su parte, los pronósticos probabilísticos se crean a partir de la implementación de distintas CIs (con perturbaciones aleatorias) en el modelo. Cada integración de una CI es definida como un miembro de un conjunto llamado ensamble ([Toth & Buizza, 2019](#); [Vitart & Robertson, 2019](#)). De esta manera, es posible calcular probabilidades, dependiendo de los umbrales que usen en las variables atmosféricas a pronosticar. Por ejemplo, los pronósticos probabilísticos ofrecen probabilidades de que llueva más de 10 mm con 5 días de anticipación. Este tipo de pronósticos tienen habilidades desde 5 días hasta 14 días –determinado como el límite de predictibilidad del pronóstico meteorológico ([E. N. Lorenz, 1975](#))– y su incertidumbre puede ser cuantificada por diversas métricas ([Toth & Buizza, 2019](#)).

1.3.2. Pronóstico subestacional

La escala del pronóstico subestacional (antes llamado pronóstico de rango extendido) abarca desde 10 días hasta 2 meses, y es conocido como el puente entre el tiempo meteorológico y el clima (Vitart et al., 2017; Vitart & Robertson, 2019; White et al., 2017). Debido a esta conexión, en esta escala las CIs siguen siendo fundamentales para la inicialización de los modelos; sin embargo, también cobran mayor relevancia los procesos asociados a la variación de la humedad del suelo, la cantidad de hielo y las SST (Mahmood et al., 2014) –variables que determinan las condiciones de frontera en el pronóstico estacional, cuya escala se define de 2 a 7 meses (Kalnay, 2002)–. En otras palabras, en la escala subestacional es influenciada por las CIs y los procesos de mayor lentitud que definen las condiciones de frontera. Esto lo confirma Dirmeyer et al. (2019), quienes destacan la variación de la humedad del suelo como una componente fundamental para el desarrollo de eventos extremos (e.g. sequías o inundaciones) en la escala subestacional. La importancia de dichas variables indica la necesidad de utilizar modelos acoplados.

Asimismo, la habilidad en el pronóstico subestacional depende, entre otros factores, de fenómenos que actúen como predictores –rasgo compartido con el pronóstico estacional, que utiliza el ENSO como fuente de predictibilidad interanual (S. Li & Robertson, 2015; Moron et al., 2019)–. Entre ellos, destacan el acoplamiento entre la atmósfera y el océano, los procesos que ocurren en la criósfera, en la estratósfera (e.g. la QBO) y la MJO. Esta última es considerada como la principal fuente de predictibilidad subestacional (Kiladis et al., 2009) debido a la influencia que ejerce no solo en los trópicos, sino a nivel global (Nakazawa, 1986) (ver secciones 1.1 y 1.2) a través de las teleconexiones. Por ejemplo, la convección tropical de la MJO puede tener teleconexiones en las latitudes medias (Lin et al., 2019) y estas, a su vez, pueden inducir cambios en la MJO por medio de perturbaciones en el flujo medio en el que se desplaza. Además, la MJO puede ser modificada por el ENSO y también fungir como su mecanismo de iniciación (Hoell et al., 2014; Krishnamurti et al., 2013; Moon et al., 2011; Olvera-Lazcano, 2022; C. Zhang & Gottschalck, 2002).

1.4. Proyecto S2S: avances y limitaciones

La escala subestacional ha cobrado relevancia en los últimos años, debido al interés en pronosticar los eventos extremos en escala de semanas (Vitart et al., 2017). Por ello, surge el proyecto subestacional a estacional (PS2S, por sus siglas en inglés). Este proyecto representa un esfuerzo conjunto de 11 centros operativos internacionales para recopilar 650 pronósticos que se producen semanalmente y hacerlos públicos (Takaya, 2019). Cada centro operativo tiene un modelo con diferentes CIs (que conforman un ensamble), que al juntar su pronóstico probabilístico con el de otros centros, produce pronósticos multi-ensamble que tienen coeficientes de correlación grandes con las observaciones al momento de realizar una evaluación de su desempeño (Buizza, 2019).

Los pronósticos subestacionales y estacionales pueden crearse usando condiciones pasadas —conocidos como repronóstico, pronóstico retrospectivo (hindcast en inglés)—, o usando condiciones en tiempo real —pronóstico en tiempo real—. Los repronósticos son fundamentales para el proceso de calibración de los modelos, ya que proporcionan la climatología del modelo utilizado para realizar evaluaciones sobre el comportamiento de los pronósticos de tiempo real (Takaya, 2019). Los ensambles del repronóstico manejan distintos periodos de años. Sin embargo, entre más grande sea el periodo del hindcast, se puede obtener más información crucial sobre sus sesgos y la habilidad del modelo (Buizza, 2019).

Existen 2 tipos de ensambles de los modelos del PS2S: el ensamble *burst* y el ensamble desfasado (LAF, por sus siglas en inglés). En el ensamble *burst*, los miembros del ensamble se inicializan al mismo tiempo, mientras que, en el ensamble desfasado, los componentes del modelo inician en tiempos consecutivos, pero en un intervalo previamente definido (Hoffman & Kalnay, 1983). Los ensambles *burst* tienen mejor habilidad predictiva en comparación con los ensambles desfasados (Takaya, 2019). Sin embargo, los LAF utilizan una menor cantidad de recursos computacionales que los ensambles *burst* y su habilidad predictiva decrece lentamente. Por ello, se les considera adecuados para el pronóstico S2S (Takaya, 2019).

El proyecto S2S cuenta con un total de 11 modelos que producen pronósticos subestacionales y estacionales en tiempo real y repronósticos (Tabla 1.1). La escala subestacional —al igual que

la estacional— requiere modelos que expliquen la interacción océano-atmósfera-suelo. Por ello, 7 de 11 ensambles (tanto en tiempo real, como repronóstico) están contruidos a partir de modelos acoplados.

Tabla 1.1. Características principales de los sistemas hindcast del PS2S. Tomado y modificado de (Buizza, 2019). La lista está actualizada con respecto a las últimas versiones de cada modelo utilizado en el estudio.

Centro Operacional	Número de años disponibles	Número de miembros inicializados cada semana	Condiciones iniciales para atmósfera y continente	Condiciones iniciales para océano/hielo marino	Versión del modelo utilizada
BMRC	34 (1981-2013)	33	ERA Interim	PEODAS	-
CMA-BCC	21 (1994-2014)	8 (4 x 2 veces a la semana)	ECMWF	BCC	-
ECCC	20 (últimos 20 años)	4	Reanálisis ERA5	ORAS5 y HadISST2.2	GEPS 7
ECMWF	20 (últimos 20 años)	22 (11 x 2 veces a la semana)	ERA5	ORAS5	CY47R3
HMCR	26 (1991-2015)	10	ERA5	-	-
IAP-CAS	20 (1999-2018)	28 (4 x 7 veces a la semana)	FNL-NCEP	FNL-NCEP	CAS-FGOALS-f2-V1.3
ISAC-CNR	30 (1981-2010)	5	ERA-Interim (T255L60)	-	-
JMA	30 (1991-2020)	5 cada dos semanas	JRA-3Q	MOVE-G3	-
KMA	20 (1993-2016)	3	ERA-Interim	MetOffice ODA	GloSea6-GC3.2
MF	25 (1993-2017)	10	ERA5	Reanálisis MERCATOR	-
NCEP	11 (1999-2010)	28 (4 x 7 veces a la semana)	CFSR	CFSR	-
UKMO	23 (1993-2016)	7	ERA-Interim	NEMOVAR	-

De manera general, el pronóstico subestacional que tiene mejor habilidad globalmente es el producido por el ECMWF (Buizza, 2019). Además, anteriormente se consideraba que los ensambles tenían mejor habilidad predictiva en los extratropicos que en las latitudes tropicales (Buizza, 2019); sin embargo, actualmente los modelos logran mayor habilidad subestacional en regiones tropicales —particularmente en el océano, debido a la influencia de la MJO y ENSO, así como a la persistencia de anomalías en el océano— (Barriopedro et al., 2023; de Andrade

et al., 2021; Wulff et al., 2022), aunque exhiben mayor subestimación en variables como la precipitación debido a la parametrización de la convección (de Andrade, Coelho, & Cavalcanti, 2018; Serra et al., 2014). A pesar de lo anterior, los ensambles tienen baja habilidad sobre el continente (S. Li & Robertson, 2015).

Los estudios realizados con datos del PS2S se han enfocado mayormente en la habilidad de los modelos para simular la intensidad, desplazamiento y teleconexiones de la MJO a nivel global con varias semanas de anticipación (Vitart et al., 2017). Por ejemplo, Domeisen et al. (2022) encontraron que el pronóstico de eventos extremos no tiene habilidad cuando la MJO no está activa; mientras que, en eventos intensos se tiene una habilidad predictiva adecuada con 2 a 3 semanas de anticipación.

A pesar de que la MJO juega un papel sumamente importante como fuente de predictibilidad en la escala subestacional, aún existen muchos problemas con respecto a su predicción, tanto en su dinámica intrínseca, como en sus teleconexiones. Woolnough (2019) encontró que gran parte de los modelos que pertenecen al PS2S subestiman la amplitud de la MJO en 10 %-40 %. Por otro lado, Matthews (2008) menciona que la predictibilidad de la MJO es menor si se trata de eventos primarios. Incluso, Wu et al. (2023) menciona que la habilidad predictiva de los eventos MJO primarios se pierde entre los 11 y 17 días. Se necesitan estudios que determinen el impacto de la diversidad de la MJO en la predicción subestacional (Chen, 2021), ya que los eventos MJO rápidos y lentos –los cuales tienen la dinámica más conocida de la MJO— tienen mayor predictibilidad que las MJO estacionarias e intermitentes. Por su parte, Stan et al. (2022) revelan que los pronósticos S2S sobreestiman las amplitudes de las teleconexiones asociadas a la MJO, considerando todas sus fases. Dirmeyer y Halder (2017) mencionan que la habilidad para predecir a escalas intraestacionales mejora cuando se considera el acoplamiento atmósfera-suelo, no sólo atmósfera-océano. Es necesario tener una mejora en estos modelos acoplados con la finalidad de producir pronósticos más hábiles. Por ejemplo, los pronósticos de temperatura subestacionales tienen diversos errores asociados a los procesos de humedad del suelo, vegetación y presión superficial, principalmente en Europa central, este de Norteamérica y sureste de Asia (Ruiz-Vásquez et al., 2022). También, se pueden presentar errores relacionados con la evolución de las variables atmosféricas, como la radiación solar que llega a la superficie.

Capítulo 2

Datos y Métodos

2.1. Reanálisis ERA5

El Centro Europeo para Pronósticos Meteorológicos de Medio Plazo (ECMWF, por sus siglas en inglés) implementó el reanálisis atmosférico ERA5 de manera operativa en el año 2020 ([Hersbach et al., 2019, 2020](#)). El ERA5 sobresale como un reanálisis de 5° generación, con una resolución espacial horizontal de 31 km, una resolución temporal horaria y tiene hasta 37 niveles de presión en altura, representando de mejor manera la atmósfera en sus diferentes niveles. Además de estas especificaciones, ERA5 se basa en el Sistema de Pronóstico Integrado (IFS, por sus siglas en inglés) para la asimilación de sus datos. Esta base de datos fue utilizada para extraer variables atmosféricas y oceánicas del Servicio de Cambio Climático Copernicus (C3S, por sus siglas en inglés) [Hersbach et al. \(2020\)](#). A continuación, se describen de manera breve cada una de las variables utilizadas en este estudio en el periodo 1980-2018:

- Radiación térmica neta superior (W/m^2): La base de datos de reanálisis ERA5 tiene la variable radiación térmica neta superior (TTR, por sus siglas en inglés), que equivale al inverso de la OLR, y es obtenida a partir de datos satelitales y las parametrizaciones del modelo de Sistema de Pronóstico Integrado (IFS, por sus siglas en inglés). Sus unidades son J/m^2 , y está acumulado en escala horaria del inicio al final del periodo determinado. Se realizó una conversión para pasar de TTR a OLR en W/m^2 y después, se restó el acumulado total con el fin de obtener la OLR horaria y posteriormente calcular el promedio diario.

- Precipitación (mm): este parámetro surge de la precipitación total de ERA5, el cual considera el agua en estado sólido y líquido que cae sobre la superficie terrestre. Los datos son obtenidos a partir la parametrización de nubes del modelo IFS. Sus unidades son metros de columna de agua. Por lo cual, se realizó una conversión de metros a milímetros (mm) de precipitación.
- Viento (m/s): el viento horizontal tiene dos componentes de acuerdo con su dirección. La componente zonal tiene valores positivos (negativos) que indican una dirección hacia el este (oeste). Estos se generan a partir del modelo IFS. La componente meridional tiene valores positivos (negativos) que indican una dirección hacia el norte (sur). Se utilizaron los datos de 3 niveles: 850 mb, 250 mb, y 10 metros.
- SST (K): La temperatura superficial del mar se expresa en unidades Kelvin. En ERA5, las SST se obtienen a partir de los modelos Análisis Operacional de Temperatura Superficial del Mar y Hielo Marino (OSTIA, por sus siglas en inglés) y el Centro Hadley de Temperatura Superficial del Mar y Hielo Marino (HADISST, por sus siglas en inglés); así como de buques.
- Flujo de calor sensible (W/m^2): se define como el promedio del flujo de calor sensible y representa la transferencia de calor entre la superficie (tierra u océano) y la atmósfera, debido a la diferencia de temperatura y al movimiento turbulento. El signo positivo (negativo) indica flujo de la atmósfera hacia la superficie (desde la superficie hacia la atmósfera)
- Flujo de calor latente (W/m^2): se define como el promedio de flujo de calor latente y representa la transferencia de calor entre la superficie (tierra u océano) y la atmósfera debido a la evaporación y la condensación del agua; es decir, debido a los cambios de fase. El signo positivo (negativo) indica un flujo de la atmósfera hacia la superficie (desde la superficie hacia la atmósfera).

Todas las variables se utilizaron a una resolución espacial de $2^\circ \times 2^\circ$, ya que en la escala subestacional no es necesaria una resolución más fina, pues a 2° ya se capturan los fenómenos de escala sinóptica.

2.2. Índices de la MJO

La MJO requiere de índices que monitoreen las variaciones espaciotemporales de su centro de convección. Previo al monitoreo en tiempo real, la oscilación intraestacional se extraía a partir de la aplicación de filtros a las anomalías de viento y OLR, siguiendo la metodología inicial propuesta por [Madden y Julian \(1971\)](#). Hasta la fecha, algunos de los estudios relacionados con la MJO continúan utilizando la técnica de filtros para extraer su variabilidad característica, ya que esta metodología es efectiva para series de tiempo previamente establecidas y para la detección de la escala subestacional. Sin embargo, no es adecuada para la detección de la MJO en tiempo real ([Wheeler & Hendon, 2004](#); [Woolnough, 2019](#)). En esta sección se describen algunos índices de monitoreo de la MJO/BSISO, los cuales se utilizaron para conocer la amplitud de la oscilación en las diferentes CIs (ver sección 2.4).

2.2.1. Índice RMM

[Wheeler y Hendon \(2004\)](#) desarrollaron el Índice Multivariado en Tiempo Real (RMMI, por sus siglas en inglés) a partir de la técnica estadística conocida como Funciones Empíricas Ortogonales (FEOs, por sus siglas, en plural) ([Brunet & Methven, 2019](#)). Las FEOs son utilizadas para describir la varianza espacial que tiene un fenómeno, y comúnmente se utilizan las dos primeras funciones que, al ser ortogonales entre ellas, fungen como una base bidimensional (2D) para el espacio de fases de las variables estudiadas del fenómeno en cuestión. [Wheeler y Hendon \(2004\)](#) calcularon las FEOs del viento a 200 mb, 850 mb y OLR (previamente extrayendo la estacionalidad y la variabilidad interanual). Al acoplarlas, se forman dos pares de FEOs que a través del espacio de fases (Figura 2.1) explican exitosamente la propagación de la MJO: la FEO1 (componente principal RMM1) describe la convección activa y debilitada situada sobre la región del Continente Marítimo. La FEO2 (componente principal RMM2) muestra el comportamiento inverso de la convección desarrollada en el océano Índico y Pacífico del oeste, es decir, cuando la convección está activa en una región, se inhibe en la otra. En conjunto, ambas bases muestran la propagación hacia el este de la MJO, además de que clasifican en número de fases del 1 al 8, de acuerdo con la región donde se localice el centro de convección; y la norma

del RMM1 y RMM2 define la amplitud de los eventos, es decir, una métrica de la intensidad de la oscilación.




Figura 2.1. Diagrama de espacio de fases del índice RMM, con las componentes principales (PCs) RMM1 y RMM2. Los puntos indican la posición (de acuerdo con el cuadrante) y amplitud (distancia del centro) de los eventos en el periodo de junio de 1974 a marzo de 2014. Los colores indican la intensidad del evento MJO basada en su amplitud. Tomado de [Lafleur et al. \(2015\)](#).

A partir de su implementación en el Bureau de Meteorología en Australia, el RMMI ha sido ampliamente utilizado para el análisis de sus efectos a nivel global ([Jiang et al., 2018](#); [Perdigón-Morales et al., 2019](#); [Shimizu et al., 2017](#); [C. Zhang, 2013](#), véase la subsección 1.2). Sin embargo, estudios posteriores de [Kikuchi et al. \(2011\)](#) y [Kiladis et al. \(2014\)](#) encontraron que el RMMI está dominado principalmente por las anomalías de viento, y la señal de OLR —la cual está ligada a la convección—, contribuye en menor medida al índice. Ante esta problemática, en ambos estudios se desarrollaron dos índices, descritos a continuación.

[Kikuchi et al. \(2011\)](#) hacen énfasis en que la variabilidad estacional de la MJO no está expresada en el RMMI, puesto que este construye las FEOs sobre todas las estaciones —en otras palabras, los valores de las PCs del RMMI son independientes de la estacionalidad— y también carecen de análisis en la estructura meridional de la oscilación —relevante por la propagación que presenta la oscilación durante el verano boreal (ver subsección 1.1.3)—.

Así, [Kikuchi et al. \(2011\)](#) utilizaron la OLR filtrada de 25 a 90 días para calcular las FEOs Extendidas (EEOFs, por sus siglas en inglés), las cuales realizan un tracking (o monitoreo) de la evolución espaciotemporal (mientras las FEOs realizan el análisis espacial a partir de

la descomposición temporal) para los meses de invierno boreal (diciembre, enero, febrero) y verano boreal (junio, julio, agosto) ([Kikuchi et al., 2011](#)). La metodología utilizada condujo a la obtención de dos modos: MJO y BSISO correspondientes al invierno y verano, respectivamente, que conforman el índice Bimodal de la Oscilación Intraestacional (BISO, por sus siglas en inglés), que explica la varianza debido a la estacionalidad. La desventaja principal que presenta es la incapacidad de fungir como herramienta de monitoreo en tiempo real como lo hace el RMMI, y los autores proponen técnicas de ventana temporal para obtener el monitoreo en tiempo real, aunque de forma suavizada.

Por su parte, [Kiladis et al. \(2014\)](#) desarrollaron el Índice de la MJO basado en OLR (OMI, por sus siglas en inglés) que, como dice su nombre, utiliza únicamente la OLR como variable para monitorear y definir a la MJO. El OMI, al igual que el RMMI, utiliza las dos primeras FEOs para su espacio fase; sin embargo, previo al cálculo de FEOs, la OLR fue filtrada de 20 a 96 días, siguiendo el método propuesto por [Kikuchi et al. \(2011\)](#). De acuerdo con [Woolnough \(2019\)](#), aquellos estudios enfocados en la variabilidad de la precipitación y en el calentamiento diabático (como la convección) se ven beneficiados con el uso de OMI. Además, [S. Wang et al. \(2018\)](#) hacen una comparativa entre los distintos índices de la oscilación intraestacional, encontrando alta similitud entre el índice BISO y OMI. Esto se fundamenta con el uso de la OLR en ambos índices, la cual refleja mejor la variabilidad estacional de la oscilación, a diferencia del RMMI. Así, el OMI es capaz de identificar la propagación tanto de la MJO, como la BSISO, hacia el norte.

Recientemente, [S. Wang et al. \(2022\)](#) desarrollaron un nuevo índice denominado Índice Multivariado para Oscilaciones Intraestacionales Tropicales (MII, por sus siglas en inglés) que utiliza el viento zonal y OLR para el cálculo de las FEOs y el filtrado pasabandas de 20 a 96 días. En dicho estudio utilizan un nuevo método: la rotación de las FEOs para la eliminación de ruido de alta frecuencia que puede ser introducido por el análisis de FEOs ([Weidman et al., 2022](#)). La implementación conjunta de los métodos en las variables originalmente usadas en el índice RMM permite una correcta representación de las transiciones estacionales en conjunto con la heterogeneidad de la estructura meridional. Además de lo anterior, las PCs logran que la varianza intraestacional sea del 77 % en contraste con el 60 % de varianza explicada por el

índice RMM. La versión en tiempo real se denomina RMII, y se calcula a partir del denominado filtro en tiempo real de 40-9 días, el cual consiste en la eliminación de la media de los 40 días previos para así obtener las anomalías y posteriormente suavizarlas con una media móvil de 9 días.

Los resultados obtenidos en los estudios deben de ser tomados con cautela, en vista de que las fechas y lugares característicos de un evento MJO pueden variar en función del índice que se utilice (Kiladis et al., 2014; Straub, 2013). Cada índice destaca por sus diferentes características: monitoreo en tiempo real sin filtrado de datos (RMM), seguimiento de las anomalías relacionadas con la convección característica de la oscilación (OMI), distinción de la oscilación según la estacionalidad (BISO) y explicación de la varianza (RMII). Los índices mencionados en este trabajo no son los únicos existentes para el monitoreo de la oscilación intraestacional; sin embargo, fueron elegidos porque destacan la evolución de los métodos para caracterizar el fenómeno. Estos mismos serán utilizados para evaluar la habilidad de los modelos para simular la MJO, mismos que se enuncian en la siguiente sección.

2.3. Descripción de los modelos climáticos de la base S2S

El PS2S produce pronósticos en modo de repronóstico (hindcast) y en tiempo real, (Takaya, 2019). De acuerdo con Takaya (2019), la configuración para un repronóstico debe considerar el tamaño, longitud del ensamble (i.e., la cantidad de miembros), el intervalo de tiempo que utiliza, la frecuencia con la que salen los resultados y el método de inicialización. En particular, el método de inicialización, denominado también método de ejecución, se divide en dos: 1) Sobre la marcha y 2) Fijo. El primer tipo de ejecución realiza la inicialización en conjunto con los pronósticos en tiempo real, facilitando de esta manera la actualización de los modelos de manera continua. El segundo tipo de ejecución produce distintos repronósticos previos a la construcción del que será utilizado, lo cual es útil para aquellos modelos que están siendo constantemente actualizados. Este último ayuda a entender mejor las características del nuevo sistema de repronóstico producido, y a calibrar los modelos utilizados a partir de los repronósticos previos al producto final. Buizza (2019) define el objetivo de la escala subestacional como la resolución de un problema global, ya que las señales y errores (referidos como el error que

tienen en la asimilación de datos y en los pronósticos) viajan a través de todo el mundo en ~ 2 -3 semanas. Este tipo de predicción es un problema tanto de las condiciones iniciales —dado que es fundamental conocer el estado inicial de la atmósfera para lograr ejecuciones cercanas a la realidad— como de las condiciones de frontera —ya que, tras 14 días, variables como la SST comienzan a evolucionar conforme se acerca la escala estacional—. A continuación, se describen los modelos operacionales utilizados para este estudio, los cuales fueron restringidos al periodo 2002-2017.

2.3.1. ECMWF

Los ensambles producidos por el ECMWF utilizan el modelo más reciente en su séptima versión. Este posee un rango de ejecución de 0 a 46 días, y una resolución espacial de ~ 32 km (método de truncamiento Tco319) sobre la horizontal, y 137 niveles verticales (en versiones anteriores, tenía 91 niveles). El ECMWF está acoplado con el modelo Núcleo para el Modelaje Europeo del océano (NEMO, por sus siglas en inglés) v3.4.1, que tiene 0.25° de resolución horizontal y 75 niveles en la vertical. El ECMWF también está acoplado con el modelo Model Louvain La Neuve de Hielo (LIM2, por sus siglas en inglés), que representa el hielo marino (criósfera). Su asimilación de datos es obtenida a partir del método 4DVar para la información atmosférica y 3DVar para datos oceánicos y de hielo marino ([Vitart et al., 2017](#)).

La inicialización de las perturbaciones iniciales se calcula por medio de vectores singulares más una perturbación de la asimilación de datos del ensamble (EDA, por sus siglas en inglés). Adicionalmente, el ECMWF realiza el cálculo de la incertidumbre dentro del modelo (debido a los procesos físicos) utilizando dos esquemas: a) Tendencia Estocástica de la Perturbación de la Parametrización (SPPT, por sus siglas en inglés) y b) Retrodispersión Estocástica de la Energía Cinética (SKEB, por sus siglas en inglés), que permite calcular la incertidumbre dentro de las perturbaciones del modelo). Finalmente, la construcción del repronóstico se hace sobre la marcha, formando 11 miembros que son generados 2 veces a la semana. Las CIs se calculan a partir del reanálisis ERA5 y del Sistema de Reanálisis Oceánico (ORAS5, por sus siglas en inglés) para la componente tierra-atmósfera y océano, respectivamente. Este modelo tiene los últimos 20 años disponibles para su uso en repronóstico. Sin embargo, es importante mencionar

que, dependiendo de la versión utilizada, será diferente el intervalo de años que esté disponible. El repronóstico que se utilizó cubre el periodo 2002-2017 ([Vitart et al., 2017](#)).

2.3.2. KMA

El modelo KMA es desarrollado en Corea del Sur en conjunto con MetOffice (Reino Unido). Debido a lo anterior, posee características similares (e.g. parametrizaciones físicas, modo operativo, etc.) al modelo de MetOffice (cuyas salidas no fueron utilizadas en este estudio debido a que el intervalo de tiempo disponible en sus repronósticos es de 1993-2015 y solo genera CIs cada jueves). El tiempo de ejecución del KMA es de 0 a 60 días con una resolución horizontal de ~ 60 km (método de truncamiento N216) y 85 niveles verticales. Este modelo está acoplado al modelo oceánico NEMO 3.6 (que tiene una resolución horizontal de 0.25° y 75 niveles verticales) y al modelo de hielo marino CICEv5.1.2. El método de asimilación de datos ocupado es 4DVar y las perturbaciones son inicializadas por medio del esquema SKEB2. El repronóstico se genera con el método sobre la marcha, obteniendo un total de 3 miembros (generados una vez a la semana). Las CIs son definidas con base en los datos de ERA-Interim y MetOffice ODA. El periodo de tiempo disponible del repronóstico es de 1993-2016. Se restringió a los años 2002-2016 ([Vitart et al., 2017](#)).

2.3.3. ECCC

El modelo canadiense ECCC produce sus perturbaciones en un periodo de pronóstico de 0 a 32 días, siendo el modelo que tiene menor duración dentro del PS2S. Las salidas se generan con una resolución horizontal de ~ 39 km (usando el tipo de malla Yin-Yang) y 81 niveles verticales. Se acopla con el modelo oceánico NEMO 3.6 (resolución horizontal de 0.25° y 50 niveles) y el modelo de hielo marino CICE4.0. Tanto la asimilación de datos como la generación de la perturbación inicial se realizan por medio del filtro de ensamble Kalman. La incertidumbre de las perturbaciones del modelo se calcula utilizando el esquema de perturbación estocástica de los parámetros –diferente al esquema SPPT utilizado por el modelo ECMWF. El repronóstico del ECCC utiliza el método sobre la marcha para la generación de ensambles, produciendo un total de 4 miembros (generados de forma semanal, todos los jueves). Las CIs se generan utilizando la información de ERA5 para la componente tierra-atmósfera, ORAS5 para el océano, y del

Servicio Canadiense del Hielo Marino (CIS, por sus siglas en inglés) acoplado con el Centro Hadley del Hielo Marino y la Temperatura de la Superficie del Mar (HadISST 2.2, por sus siglas en inglés) para el hielo marino. Finalmente, el periodo de años en el que se encuentre disponible la información del repronóstico de los últimos 20 años depende de la versión del modelo utilizado. Los años utilizados son de 2002 a 2017 ([Vitart et al., 2017](#)).

2.3.4. IAP-CAS

El modelo IAP-CAS forma parte del PS2S a partir del año 2021, siendo el segundo modelo implementado en el S2S por parte de China. Este modelo pronostica en un plazo de 0 a 65 días de antelación, siendo el modelo que tiene el mayor rango de tiempo en el PS2S. Su resolución horizontal es de ~ 45 km (método de truncamiento C96) y 32 niveles verticales. Utiliza los modelos POP2 (1° de resolución horizontal y 6 niveles verticales) y CICE4 para obtener el acoplamiento con el océano y hielo marino, respectivamente. Su método de asimilación de datos es el nudging FNL (final, en inglés) del NCEP en conjunto con el GFS. La perturbación inicial se genera por medio del esquema LAF. Sin embargo, no calcula la incertidumbre del modelo. El repronóstico utiliza el método fijo para la generación de un ensamble de 4 miembros (producidos todos los días). Las CIs son generadas a partir de Análisis Global Operacional Final de NCEP. Finalmente, el repronóstico tiene un periodo disponible de 1999-2018 ([Vitart et al., 2017](#)).

2.4. Definición de eventos MJO y BSISO

Este estudio considera que la oscilación intraestacional tiene 2 comportamientos que dependen de la estacionalidad: la MJO que se presenta durante invierno y la BSISO que se presenta en verano. El inicio de cada evento de la MJO y la BSISO se utilizaron como las CIs de los modelos descritos anteriormente. Este trabajo utiliza la metodología –descrita a continuación– propuesta por [B. Wang et al. \(2019\)](#) para definir los eventos de MJO y la metodología propuesta por [Chen y Wang \(2021\)](#) para definir los eventos de BSISO. Los datos fueron procesados en MATLAB. Para definir los eventos de la MJO y la BSISO durante el periodo 1980-2018, se utilizó la base de datos de OLR de ERA5. Esto representa una diferencia con respecto a los

estudios de [B. Wang et al. \(2019\)](#) y [Chen y Wang \(2021\)](#), que utilizaron datos interpolados de la NOAA. Los tipos de MJO obtenidos con los datos de ERA5 tienen características diferentes en velocidad y propagación para los casos de la MJO comparados con los resultados de [B. Wang et al. \(2019\)](#). El procedimiento en común que tienen ambas metodologías es la extracción ciclo estacional y la media temporal (i.e., la media total de la serie de tiempo de cada punto de malla). Posteriormente, se realiza un filtrado pasabandas –con sus frecuencias descritas a continuación–, seguido de la definición de una caja regional donde se ubica el inicio de los eventos y, por último, se realiza un análisis de clúster.

2.4.1. Eventos MJO durante invierno

De acuerdo con [B. Wang et al. \(2019\)](#), la MJO en invierno tiene una frecuencia de incidencia de 20 a 70 días –aunque se puede extender hasta 120 días de acuerdo con [Madden y Julian \(1972\)](#) y [C. Zhang \(2013\)](#)–, por lo que se realizó un filtrado pasa-bandas de 20 a 70 días. Una vez obtenida la variable filtrada, se definió una caja regional para calcular los eventos MJO. Se considera que la mayor parte de los eventos de la MJO ocurren en el océano Índico en las coordenadas 10°N - 10°S y 74°E - 96°E . Posteriormente, se eliminaron los datos que corresponden a los meses de mayo a octubre, con el objetivo de analizar la caja regional considerando solamente los meses de noviembre a abril –dichos meses se definen como invierno boreal–. Después, se realizó un promedio de los valores de OLR, obteniendo un valor por cada día de la serie de tiempo y se calculó la desviación estándar de los promedios de la caja obtenidos en el paso previo. Los valores promedio de la caja que son menores a una desviación estándar durante un mínimo de cinco días sucesivos, fueron considerados como eventos MJO durante invierno. El valor mínimo de OLR de cada evento se usó como el día de referencia; es decir, el día 0 (día en el que inicia cada evento).

El análisis de clúster para la MJO se efectuó sobre diagramas Hovmöller (i.e., solamente usando la longitud y el tiempo), considerando las coordenadas 14°N - 14°S y 64°E - 160°W . Los diagramas se construyeron cubriendo un total de 31 días, definidos a partir del día cero, considerando 10 días antes de que se formara y 20 días después de su formación. Después, se calculó la media móvil de 3 puntos zonales para la reducción de ruido, y se promedió la franja zonal para finalizar la construcción de los diagramas. Este procedimiento se efectuó para cada evento

MJO durante el periodo 1980-2018. Se utilizó la correlación como medida de similitud entre los diagramas para organizarlos por clúster. Finalmente, se calculó el valor de la Silueta, medida utilizada para cuantificar la similitud entre los miembros de cada clúster. Los valores de la Silueta varían de -1 a 1. Siguiendo el método de [B. Wang et al. \(2019\)](#), los miembros con un valor de la Silueta menor a 0.06 se consideraron poco similares.

Además de lo anterior, se calcularon las velocidades de fase para los compuestos del análisis de clúster de la MJO rápida y lenta. Para cada caso, se utilizó la metodología propuesta por [Wei et al. \(2023\)](#). Este método parte del diagrama Hovmöller, toma los valores mínimos de OLR, correspondientes al centro de convección de la MJO en segmentos de 10° de longitud desde 60°W , hasta que el mínimo de anomalías de OLR es mayor a -5 W/m^2 . Finalmente, estos mínimos se utilizaron en un ajuste de mínimos cuadrados. Lo anterior sirvió para calcular una pendiente, que se convirtió de unidades día/longitud (debido a que la pendiente es y/x) a metros/segundo.

2.4.2. Eventos BSISO durante verano

Para el verano boreal, se utilizó un filtro pasa-bandas de 30 a 80 días y una caja regional diferente a la utilizada para la MJO de invierno ([Chen, 2021](#)). Las coordenadas utilizadas son 10°N - 6°S y 80°E - 100°E , considerando únicamente los meses de mayo a octubre —que conforman el verano boreal—. Para la selección de eventos, se calculó la media de la caja regional; es decir, un solo valor por día durante el periodo 1980-2018. A este valor diario, se le restó la desviación estándar y la media de dichos promedios. Todo valor de la caja que sea menor a esta diferencia se considera como evento BSISO. A diferencia de la metodología para eventos de invierno, los eventos de BSISO no consideran días consecutivos. El valor mínimo se define como el día de referencia; es decir, el día de inicio del evento.

Debido a que la BSISO tiene un desplazamiento hacia el norte y simultáneamente al este, el análisis de clúster no se realizó utilizando diagramas Hovmöller. En su lugar, realiza hace sobre pentadas; es decir, el promedio de 5 días consecutivos. Se utilizaron 5 pentadas: pentada -1, 0, 1, 2, 3; donde la pentada 0 tiene el día de referencia (día de inicio del evento) en su centro. Así,

se consideraron un total de 25 días para cada evento BSISO en el análisis clúster y se utilizó la métrica del cuadrado euclidiano. Con respecto al valor de la Silueta, siguiendo a [Chen y Wang \(2021\)](#), los eventos que tienen valores de la Silueta menores a 0.05 son poco similares.

2.5. Compuestos

Una vez obtenidos los eventos MJO y BSISO, se calcularon los compuestos de las variables descritas en la sección 2.1 y fueron graficados utilizando el método de las pentadas de la sección anterior. Los compuestos de OLR y vientos (850 mb, 200 mb y 10 m) se consiguieron extrayendo la media total y filtrando según el caso de invierno y verano (i.e., de 20 a 70 días, y de 30 a 80 días, respectivamente). Esto, debido a que el campo de vientos y la OLR son las variables con las que la señal de la MJO/BSISO es caracterizada.

Por otro lado, los compuestos de precipitación se calcularon por medio de anomalías porcentuales, siguiendo el método utilizado por ([Olvera-Lazcano, 2022](#)). Su ecuación es la siguiente:

$$P_a = \frac{P - \bar{P}}{\bar{P}} \times 100 \% \quad (2.1)$$

Donde \bar{P} es la media climatológica y P los valores diarios de precipitación. Este tipo de anomalías son importantes porque la magnitud de la precipitación varía dependiendo la región y por ello, las anomalías porcentuales expresan las variaciones locales.

Para las SST, se obtuvieron los compuestos en términos de la anomalía estandarizada, cuya ecuación es la siguiente:

$$z_i = \frac{x_i - \bar{x}}{S} \quad (2.2)$$

Donde x_i corresponde al i-ésimo valor de la variable, \bar{x} es la media climatológica, y S la desviación estándar.

Para los flujos de calor sensible y latente se calcularon anomalías, es decir, solamente se restó la media climatológica sobre los valores.

Finalmente, con el objetivo de evaluar la significancia de las anomalías durante días de MJO y BSISO se calculó la prueba T de Student de dos muestras, cuya ecuación es la siguiente (Wilks, 2019):

$$z = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{s_x^2}{n} + \frac{s_y^2}{m}}} \quad (2.3)$$

En esta ecuación, \bar{x} representa la media de las anomalías de cada pentada (muestra de tamaño n) y \bar{y} corresponde a la media de las anomalías de los días sin MJO/BSISO (muestra de tamaño m); es decir, aquellos datos que no corresponden a ningún evento MJO/BSISO). Las variables s_x^2 y s_y^2 son las desviaciones estándar de las anomalías de cada pentada y de los días sin MJO/BSISO, respectivamente. En esta prueba, la hipótesis nula es que las medias de las dos muestras son iguales; mientras que la hipótesis alternativa indica que las medias de las dos muestras son diferentes. Con ello, es posible determinar si las anomalías de MJO y BSISO son significativamente diferentes de las anomalías en días sin MJO y BSISO, utilizando el intervalo de confianza del 95 % (p-value=0.05).

2.6. Métricas para evaluar los pronósticos subestacionales

La verificación de los pronósticos es fundamental para conocer el origen de los errores en los modelos cuando simulan distintos fenómenos meteorológicos. Los estudios de los métodos de verificación son diversos, y, por lo tanto, existe un gran número de métricas destinadas a evaluar los pronósticos (e.g., Coelho et al., 2019; Jolliffe & Stephenson, 2012). Una de las dificultades de la verificación subestacional es que en esta escala se comparten similitudes con el pronóstico meteorológico y el pronóstico estacional al ser el puente entre el tiempo y el clima (C. Zhang, 2013). Coelho et al. (2019) mencionan la necesidad de tener datos diarios y series de tiempo largas para realizar una evaluación robusta.

Para este estudio, se utiliza el marco definido por Coelho et al. (2018), donde las métricas de correlación de Pearson, Mean Square Skill Score (MSSS, por sus siglas en inglés), la tasa de desviación estándar del modelo y las observaciones son esenciales para obtener un panorama completo de evaluación determinística. El uso de estas métricas parte de la representación de las variables meteorológicas como anomalías de la climatología de las CIs (sesgo sistémico de

los modelos). Para obtener la climatología de la CIs de cada miembro, se descargaron todas las CIs de cada miembro del modelo durante el mismo día y mes, pero considerando todos los años del periodo de estudio. Por ejemplo, se obtuvieron 16 años de la CI del 6 de mayo para cada miembro del modelo. Una vez adquiridas todas las CIs de cada miembro, se calcula su media climatológica (promedio), y posteriormente se calcula la anomalía del miembro, como una diferencia del año en que inicia el evento (e.g. 6 de mayo del 2003) menos la climatología del miembro. Después, se calcula el promedio del ensamble (conocido como ensemble mean), que corresponde a la media de todos los miembros del ensamble de cada modelo. Finalmente, el promedio de las anomalías (ensemble mean) se compara con las observaciones (proporcionadas por el ERA5), que también deben ser expresadas en términos de anomalías.

2.6.1. Correlación

Dentro de la verificación subestacional, el análisis de correlación es ampliamente usado para definir la habilidad del modelo. La medida comúnmente utilizada es el coeficiente de correlación de Pearson (r), que mide la relación lineal entre las observaciones y el modelo (Coelho et al., 2019); es decir, es una métrica asociativa.

$$r = \frac{\sum_{i=1}^N (F_i - \bar{F})(O_i - \bar{O})}{\sqrt{\sum_{i=1}^N (F_i - \bar{F})^2} \sqrt{\sum_{i=1}^N (O_i - \bar{O})^2}} \quad (2.4)$$

En la ecuación 2.4, r es el coeficiente de correlación de Pearson, F representa los valores de los modelos, O representa los valores de las observaciones (para este estudio es el reanálisis) y N es el número total de elementos (que corresponde al número de casos analizados). El subíndice i define el i -ésimo valor de la observación o del pronóstico. El coeficiente r tiene valores entre -1 y 1, siendo 1 (-1) un indicativo de que el modelo y las observaciones guardan una correlación positiva (negativa). La medición de correlación para anomalías (también llamado coeficiente de correlación de anomalías ACC) es utilizado para cuantificar la habilidad (skill) potencial de un modelo. En este estudio, se consideró que un valor de r superior a 0.6 indica una correlación alta, mientras que un valor de r entre 0.4 y 0.6 representa una correlación moderada. Finalmente,

los valores de r inferiores a 0.4 fueron interpretados como indicativos de una correlación baja o débil.

Para robustecer los resultados de la correlación, se utilizó la prueba T de una muestra, cuya hipótesis nula establece que el valor de correlación es igual a cero, y la hipótesis alternativa indica que el valor de r es diferente de cero con un intervalo de confianza de 95 %.

2.6.2. Correlación de Spearman

Aunque la correlación de Pearson es ampliamente utilizada como parte de la verificación en pronósticos determinísticos (Coelho et al., 2019; de Andrade et al., 2021; Y. Li et al., 2021; Lyu et al., 2022; Peng et al., 2023), en este estudio también se calculó la correlación de Spearman, la cual utiliza rangos para medir la asociación entre dos poblaciones. Su intervalo de valores es igual al de la correlación de Pearson, solo que, para la correlación de Spearman, los valores indican mayor o menor asociación que no necesariamente es lineal (Hauke & Kossowski, 2011; Pérez, 2022). Su ecuación es la siguiente:

$$\rho_s = 1 - \frac{6 \sum_{i=1}^N (x_i - y_i)^2}{n(n^2 - 1)} \quad (2.5)$$

Donde x y y son los valores pronosticados y observados, respectivamente, en orden ascendente; y n el número de datos. Los valores de correlación de Spearman se clasifican de igual forma que los valores de correlación de Pearson.

2.6.3. Índice Cuadrático Promedio de Habilidad (MSSS, por sus siglas en inglés)

El MSSS es métrica que cuantifica la habilidad del modelo para pronósticos determinísticos. La habilidad (skill) evalúa la precisión de un modelo o pronóstico de acuerdo con una predicción de referencia (de Andrade et al., 2021; Murphy, 1988). Así, el MSSS se define como una medida diagnóstica de la habilidad para pronósticos determinísticos (Han et al., 2023; Y. Li et al.,

2021). Su ecuación es la siguiente:

$$MSSS = 1 - \frac{MSE_f}{MSE_c} = 1 - \frac{1}{T} \left(\frac{\sum_{t=1}^T (f_t - O_t)^2}{\sum_{t=1}^T (\bar{O} - O_t)^2} \right) \quad (2.6)$$

Donde MSE_f es el error cuadrático medio del pronóstico contra las observaciones; MSE_c es el error cuadrático medio de un pronóstico de referencia. Del lado derecho de la ecuación, f_t y O_t son las anomalías del ensamble de pronóstico y las anomalías de las observaciones, respectivamente; y \bar{O} es el promedio de las anomalías de las observaciones. Siguiendo la estructura de Coelho et al. (2018), el pronóstico de referencia para el presente estudio es la climatología observada, en otras palabras, la diferencia entre las anomalías observadas y el promedio de las anomalías \bar{O} como se muestra en la ecuación 2.6.

Dado que el MSSS contiene información sobre el error de fase y el error de amplitud según los estudios de Murphy (1988) y Murphy y Epstein (1989), el MSSS se descompone en la correlación (que da información sobre el error de fase) y la tasa de la desviación estándar (error de amplitud) del modelo contra las observaciones para describir los errores de fase y amplitud, respectivamente. Sin embargo, en este estudio se presentan solamente las métricas de correlación y del MSSS.

Los valores del MSSS tienen un intervalo de $[-\infty, 1]$, donde 0 indica que la habilidad del modelo es igual que la habilidad del pronóstico de referencia; es decir, la climatología observada. Valores mayores a 0 indican que el modelo es mejor que el pronóstico de referencia, y valores negativos indican que el modelo es peor, en otras palabras, que el modelo no posee habilidad.

2.7. Verificación Difusa

En el pronóstico subestacional, la resolución espacial debe ser menor comparada con la del pronóstico meteorológico, debido a que en una escala espacial fina, los errores y las perturbaciones aumentan considerablemente desde los 14 días de pronóstico (Palmer & Hagedorn, 2006; Vitart & Robertson, 2019). Lo anterior se complementa con los hallazgos de Ebert (2008) y Rossa et al. (2008), quienes destacan que a través del uso de productos de alta resolución espacial, es posible perder exactitud al comparar los puntos de malla con las observaciones. Para

corregir esto, [Ebert \(2008\)](#) sugiere distintos tipos de verificación difusa en el que se definen vecindades a través de distintas técnicas, entre las cuales se encuentran los promedios (o upscaling en inglés), umbrales, o la generación de funciones de densidad de probabilidad (PDFs, por sus siglas en inglés).

La verificación difusa por promedio se calcula a partir de la definición de vecindades: para cada punto de malla, el valor será igual al promedio de una vecindad de n puntos; es decir, una suavización del valor real. En el presente estudio, se definió una vecindad de 6 puntos. Esto quiere decir que, para cada punto de malla de las variables (con resolución espacial de 2°), se realizó un promedio tomando en cuenta los 3 puntos de malla contiguos y el punto mismo. De esta manera, el promedio se hace con una suavización de $12 \times 12^\circ$. La figura 2.2 ilustra el procedimiento, donde el punto de malla central poseerá el valor promedio de los puntos circundantes. Esto se repite para cada punto de malla en la región de estudio.




Figura 2.2. Estrategia de verificación difusa a partir del promedio de vecindades. Las regiones grises denotan las vecindades promediadas. Tomado de [Ebert \(2008\)](#).

Debido a que la escala subestacional comienza a partir de dos semanas (aunque tras diez días se considera la escala del pronóstico extendido), no se realizará una verificación de la escala diaria ([S. Li & Robertson, 2015](#); [Coelho et al., 2018, 2019](#)). Se realizará una verificación a nivel semanal; es decir, el cálculo de anomalías promedio por cada 7 días.

Referencias

- Adames, A., & Kim, D. (2016). The mjo as a dispersive, convectively coupled moisture wave: Theory and observations. *Journal of the Atmospheric Sciences*, 73(3), 913 - 941. doi: [10.1175/JAS-D-15-0170.1](https://doi.org/10.1175/JAS-D-15-0170.1)
- Adams, D. K., & Comrie, A. C. (1997). The north american monsoon. *Bulletin of the American Meteorological Society*, 78(10), 2197-2214. doi: [10.1175/1520-0477\(1997\)078<2197:TNAM>2.0.CO;2](https://doi.org/10.1175/1520-0477(1997)078<2197:TNAM>2.0.CO;2)
- Alaka, G. J., & Maloney, E. D. (2012). The influence of the mjo on upstream precursors to african easterly waves. *Journal of Climate*, 25(9), 3219 - 3236. doi: [10.1175/JCLI-D-11-00232.1](https://doi.org/10.1175/JCLI-D-11-00232.1)
- Alcántara-Ayala, I. (2019). Desastres en México: mapas y apuntes sobre una historia inconclusa. *Investigaciones Geográficas*(100). doi: [10.14350/rig.60025](https://doi.org/10.14350/rig.60025)
- Back, S.-Y., Han, J.-Y., & Son, S.-W. (2020). Modeling evidence of qbo-mjo connection: A case study. *Geophysical Research Letters*, 47(20), e2020GL089480. (e2020GL089480 2020GL089480) doi: <https://doi.org/10.1029/2020GL089480>
- Barriopedro, D., García-Herrera, R., Ordóñez, C., Miralles, D. G., & Salcedo-Sanz, S. (2023). Heat waves: Physical understanding and scientific challenges. *Reviews of Geophysics*, 61(2), e2022RG000780. doi: <https://doi.org/10.1029/2022RG000780>
- Brunet, G., & Methven, J. (2019). Chapter 4 - identifying wave processes associated with predictability across time scales: An empirical normal mode approach. En A. W. Robertson & F. Vitart (Eds.), *Sub-seasonal to seasonal prediction* (p. 65-90). Elsevier. doi: <https://doi.org/10.1016/B978-0-12-811714-9.00004-8>
- Buizza, R. (2019). Chapter 13 - ensemble generation: The tigge and s2s ensembles. En A. W. Robertson & F. Vitart (Eds.), *Sub-seasonal to seasonal prediction* (p. 261-303). Elsevier. doi: <https://doi.org/10.1016/B978-0-12-811714-9.00013-9>
- CENAPRED. (2019). Desastres en México: impacto social y económico. *CENAPRED*. Descargado de <http://www.cenapred.unam.mx/es/Publicaciones/archivos/318-INFOGRAFADESASTRESENMXICO-IMPACTOSOCIALYECONMICO.PDF>

- Chen, G. (2021). Diversity of the global teleconnections associated with the madden–julian oscillation. *Journal of Climate*, 34(1), 397 - 414. Descargado de <https://journals.ametsoc.org/view/journals/clim/34/1/JCLI-D-20-0357.1.xml> doi: 10.1175/JCLI-D-20-0357.1
- Chen, G., & Wang, B. (2021). Diversity of the boreal summer intraseasonal oscillation. *Journal of Geophysical Research: Atmospheres*, 126(8), e2020JD034137. doi: <https://doi.org/10.1029/2020JD034137>
- Coelho, C. A., Brown, B., Wilson, L., Mittermaier, M., & Casati, B. (2019). Chapter 16 - forecast verification for s2s timescales. En A. W. Robertson & F. Vitart (Eds.), *Sub-seasonal to seasonal prediction* (p. 337-361). Elsevier. doi: <https://doi.org/10.1016/B978-0-12-811714-9.00016-4>
- Coelho, C. A., Firpo, M. A., & de Andrade, F. M. (2018). A verification framework for south american subseasonal precipitation predictions. *Meteorologische Zeitschrift*, 27(6), 503-520. doi: [10.1127/metz/2018/0898](https://doi.org/10.1127/metz/2018/0898)
- de Andrade, F. M., Coelho, C. A. S., & Cavalcanti, I. F. A. (2018). Global precipitation hindcast quality assessment of the subseasonal to seasonal (s2s) prediction project models. *Climate Dynamics*, 52, 5451-5475.
- de Andrade, F. M., Young, M. P., MacLeod, D., Hirons, L. C., Woolnough, S. J., & Black, E. (2021). Subseasonal precipitation prediction for africa: Forecast evaluation and sources of predictability. *Weather and Forecasting*, 36(1), 265 - 284. doi: [10.1175/WAF-D-20-0054.1](https://doi.org/10.1175/WAF-D-20-0054.1)
- DeMott, C. A., Klingaman, N. P., Tseng, W.-L., Burt, M. A., Gao, Y., & Randall, D. A. (2019). The convection connection: How ocean feedbacks affect tropical mean moisture and mjo propagation. *Journal of Geophysical Research: Atmospheres*, 124(22), 11910-11931. doi: <https://doi.org/10.1029/2019JD031015>
- DeMott, C. A., Klingaman, N. P., & Woolnough, S. J. (2015). Atmosphere-ocean coupled processes in the madden-julian oscillation. *Reviews of Geophysics*, 53(4), 1099-1154. doi: <https://doi.org/10.1002/2014RG000478>
- Dirmeyer, P. A., Gentine, P., Ek, M. B., & Balsamo, G. (2019). Chapter 8 - land surface processes relevant to sub-seasonal to seasonal (s2s) prediction. En A. W. Robertson & F. Vitart (Eds.), *Sub-seasonal to seasonal prediction* (p. 165-181). Elsevier. doi: <https://doi.org/10.1016/B978-0-12-811714-9.00008-5>
- Dirmeyer, P. A., & Halder, S. (2017). Application of the land–atmosphere coupling paradigm to the operational coupled forecast system, version 2 (cfsv2). *Journal of Hydrometeorology*, 18(1), 85 - 108. doi: [10.1175/JHM-D-16-0064.1](https://doi.org/10.1175/JHM-D-16-0064.1)

- Domeisen, D. I. V., White, C. J., Afargan-Gerstman, H., Ángel G. Muñoz, Janiga, M. A., Vitart, F., ... Tian, D. (2022). Advances in the subseasonal prediction of extreme events: Relevant case studies across the globe. *Bulletin of the American Meteorological Society*, 103(6), E1473 - E1501. doi: [10.1175/BAMS-D-20-0221.1](https://doi.org/10.1175/BAMS-D-20-0221.1)
- Dominguez, C., Jaramillo, A., & Cuéllar, P. (2021). Are the socioeconomic impacts associated with tropical cyclones in Mexico exacerbated by local vulnerability and ENSO conditions? *International Journal of Climatology*, 41(S1), E3307-E3324. doi: <https://doi.org/10.1002/joc.6927>
- Ebert, E. E. (2008). Fuzzy verification of high-resolution gridded forecasts: a review and proposed framework. *Meteorological Applications*, 15(1), 51-64. doi: <https://doi.org/10.1002/met.25>
- Emanuel, K. A. (1986). An air-sea interaction theory for tropical cyclones. part i: Steady-state maintenance. *Journal of Atmospheric Sciences*, 43(6), 585 - 605. doi: [10.1175/1520-0469\(1986\)043<0585:AASITF>2.0.CO;2](https://doi.org/10.1175/1520-0469(1986)043<0585:AASITF>2.0.CO;2)
- Fuchs, Ž., & Raymond, D. (2005). Large-scale modes in a rotating atmosphere with radiative-convective instability and waves. *Journal of the Atmospheric Sciences*, 62(11), 4084-4094. doi: [10.1175/JAS3582.1](https://doi.org/10.1175/JAS3582.1)
- Fuchs, Ž., & Raymond, D. (2017). A simple model of intraseasonal oscillations. *Journal of Advances in Modeling Earth Systems*, 9(2), 1195-1211. doi: <https://doi.org/10.1002/2017MS000963>
- Giraldo-Cardenas, S., Arias, P. A., Vieira, S. C., & Zuluaga, M. D. (2022). Easterly waves and precipitation over northern South America and the Caribbean. *International Journal of Climatology*, 42(3), 1483-1499. doi: <https://doi.org/10.1002/joc.7315>
- Han, J.-Y., Kim, S.-W., Park, C.-H., & Son, S.-W. (2023). Ensemble size versus bias correction effects in subseasonal-to-seasonal (S2S) forecasts. *Geoscience Letters*, 10(1), 37. doi: [10.1186/s40562-023-00292-9](https://doi.org/10.1186/s40562-023-00292-9)
- Hauke, J., & Kossowski, T. (2011). Comparison of values of Pearson's and Spearman's correlation coefficients on the same sets of data. *Quaestiones Geographicae*, 30(2), 87-93. doi: [doi:10.2478/v10117-011-0021-1](https://doi.org/10.2478/v10117-011-0021-1)
- Hayashi, M., & Itoh, H. (2017). A new mechanism of the slow eastward propagation of unstable disturbances with convection in the tropics: Implications for the MJO. *Journal of the Atmospheric Sciences*, 74(11), 3749 - 3769. doi: [10.1175/JAS-D-16-0300.1](https://doi.org/10.1175/JAS-D-16-0300.1)
- He, Z., Hsu, P., Liu, X., Wu, T., & Gao, Y. (2019). Factors limiting the forecast skill of the boreal summer intraseasonal oscillation in a subseasonal-to-seasonal model. *Advances in Atmospheric Sciences*, 36, 104-118. doi: [10.1007/s00376-018-7242-3](https://doi.org/10.1007/s00376-018-7242-3)

- Henderson, S. A., Maloney, E. D., & Barnes, E. A. (2016). The influence of the madden–julian oscillation on northern hemisphere winter blocking. *Journal of Climate*, 29(12), 4597–4616. doi: [10.1175/JCLI-D-15-0502.1](https://doi.org/10.1175/JCLI-D-15-0502.1)
- Hendon, H. H., & Salby, M. L. (1994). The life cycle of the madden–julian oscillation. *Journal of Atmospheric Sciences*, 51(15), 2225–2237. doi: [https://doi.org/10.1175/1520-0469\(1994\)051<2225:TLCOTM>2.0.CO;2](https://doi.org/10.1175/1520-0469(1994)051<2225:TLCOTM>2.0.CO;2)
- Hersbach, H., Bell, B., Berrisford, P., Hirahara, S., Horányi, A., Muñoz-Sabater, J., ... Thépaut, J.-N. (2020). The era5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 146(730), 1999–2049. doi: <https://doi.org/10.1002/qj.3803>
- Hersbach, H., Bell, W., Berrisford, P., Horányi, A., J., M.-S., Nicolas, J., ... Dee, D. (2019). Global reanalysis: goodbye era-interim, hello era5. *Quarterly Journal of the Royal Meteorological Society*, 17–24. doi: [10.21957/vf291hehd7](https://doi.org/10.21957/vf291hehd7)
- Hoell, A., Barlow, M., Wheeler, M. C., & Funk, C. (2014). Disruptions of el niño–southern oscillation teleconnections by the madden–julian oscillation. *Geophysical Research Letters*, 41(3), 998–1004. doi: <https://doi.org/10.1002/2013GL058648>
- Hoffman, R. N., & Kalnay, E. (1983). Lagged average forecasting, an alternative to monte carlo forecasting. *Tellus A*, 35A(2), 100–118. doi: <https://doi.org/10.1111/j.1600-0870.1983.tb00189.x>
- Huang, B., L’Heureux, M., Hu, Z.-Z., & Zhang, H.-M. (2016). Ranking the strongest enso events while incorporating sst uncertainty. *Geophysical Research Letters*, 43(17), 9165–9172. doi: <https://doi.org/10.1002/2016GL070888>
- Jiang, X., Xiang, B., Zhao, M., Li, T., Lin, S.-J., Wang, Z., & Chen, J.-H. (2018). Intraseasonal tropical cyclogenesis prediction in a global coupled model system. *Journal of Climate*, 31(15), 6209–6227. doi: [10.1175/JCLI-D-17-0454.1](https://doi.org/10.1175/JCLI-D-17-0454.1)
- Jin, F., & Hoskins, B. J. (1995). The direct response to tropical heating in a baroclinic atmosphere. *Journal of Atmospheric Sciences*, 52(3), 307–319. doi: [10.1175/1520-0469\(1995\)052<0307:TDRTH>2.0.CO;2](https://doi.org/10.1175/1520-0469(1995)052<0307:TDRTH>2.0.CO;2)
- Jolliffe, I. T., & Stephenson, D. B. (2012). *Forecast verification: a practitioner’s guide in atmospheric science*. John Wiley & Sons.
- Kalnay, E. (2002). *Atmospheric modeling, data assimilation and predictability*. Cambridge University Press.
- Kikuchi, K. (2021). The boreal summer intraseasonal oscillation (bsiso): A review. *Journal of the Meteorological Society of Japan. Ser. II, advpub*, 2021–045. doi: [10.2151/jmsj.2021-045](https://doi.org/10.2151/jmsj.2021-045)

- Kikuchi, K., Wang, B., & Kajikawa, Y. (2011). Bimodal representation of the tropical intraseasonal oscillation. *Climate Dynamics - CLIM DYNAM*, 38, 1-12. doi: [10.1007/s00382-011-1159-1](https://doi.org/10.1007/s00382-011-1159-1)
- Kiladis, G. N., Dias, J., Straub, K. H., Wheeler, M. C., Tulich, S. N., Kikuchi, K., ... Ventrice, M. J. (2014). A comparison of olr and circulation-based indices for tracking the mjo. *Monthly Weather Review*, 142(5), 1697 - 1715. doi: [10.1175/MWR-D-13-00301.1](https://doi.org/10.1175/MWR-D-13-00301.1)
- Kiladis, G. N., Wheeler, M. C., Haertel, P. T., Straub, K. H., & Roundy, P. E. (2009). Convectively coupled equatorial waves. *Reviews of Geophysics*, 47(2). doi: <https://doi.org/10.1029/2008RG000266>
- Kim, D., Kug, J.-S., & Sobel, A. H. (2014). Propagating versus nonpropagating madden-julian oscillation events. *Journal of Climate*, 27(1), 111 - 125. doi: [10.1175/JCLI-D-13-00084.1](https://doi.org/10.1175/JCLI-D-13-00084.1)
- Klingaman, N. P., & Woolnough, S. J. (2014). The role of air-sea coupling in the simulation of the madden-julian oscillation in the hadley centre model. *Quarterly Journal of the Royal Meteorological Society*, 140(684), 2272-2286. doi: <https://doi.org/10.1002/qj.2295>
- Klotzbach, P. J. (2014). The madden-julian oscillation's impacts on worldwide tropical cyclone activity. *Journal of Climate*, 27(6), 2317 - 2330. doi: [10.1175/JCLI-D-13-00483.1](https://doi.org/10.1175/JCLI-D-13-00483.1)
- Knutson, T. R., & Weickmann, K. M. (1987). 30-60 day atmospheric oscillations: Composite life cycles of convection and circulation anomalies. *Monthly Weather Review*, 115(7), 1407-1436. doi: [10.1175/1520-0493\(1987\)115<1407:DAOCLC>2.0.CO;2](https://doi.org/10.1175/1520-0493(1987)115<1407:DAOCLC>2.0.CO;2)
- Krishnamurti, T., Stefanova, L., & Misra, V. (2013). *Tropical meteorology*. Springer New York, NY. doi: <https://doi.org/10.1007/978-1-4614-7409-8>
- Lafleur, D. M., Barrett, B. S., & Henderson, G. R. (2015). Some climatological aspects of the madden-julian oscillation (mjo). *Journal of Climate*, 28(15), 6039 - 6053. doi: [10.1175/JCLI-D-14-00744.1](https://doi.org/10.1175/JCLI-D-14-00744.1)
- Laing, A., & Evans, J. (2016). *Introduction to tropical meteorology. a comprehensive online & print textbook*. (2.^a ed.). The COMET Program.
- Lee, H., & Seo, K.-H. (2019). Impact of the madden-julian oscillation on antarctic sea ice and its dynamical mechanism. *Scientific Reports*, 9, 10761. doi: [10.1038/s41598-019-47150-3](https://doi.org/10.1038/s41598-019-47150-3)
- Li, S., & Robertson, A. W. (2015). Evaluation of submonthly precipitation forecast skill from global ensemble prediction systems. *Monthly Weather Review*, 143(7), 2871 - 2889. doi: [10.1175/MWR-D-14-00277.1](https://doi.org/10.1175/MWR-D-14-00277.1)
- Li, Y., Wu, Z., He, H., & Lu, G. (2021). Deterministic and probabilistic evaluation of sub-seasonal precipitation forecasts at various spatiotemporal scales over china during the boreal summer monsoon. *Atmosphere*, 12(8). doi: [10.3390/atmos12081049](https://doi.org/10.3390/atmos12081049)

- Li, Z., Li, Y., Bonsal, B., Manson, A. H., & Scaff, L. (2018). Combined impacts of enso and mjo on the 2015 growing season drought on the canadian prairies. *Hydrology and Earth System Sciences*, 22(10), 5057–5067. doi: <https://doi.org/10.5194/hess-22-5057-2018>
- Lin, H. (2022). The madden-julian oscillation. *Atmosphere-Ocean*, 60(3-4), 338-359. doi: [10.1080/07055900.2022.2072267](https://doi.org/10.1080/07055900.2022.2072267)
- Lin, H., Frederiksen, J., Straus, D., & Stan, C. (2019). Chapter 7 - tropical-extratropical interactions and teleconnections. En A. W. Robertson & F. Vitart (Eds.), *Sub-seasonal to seasonal prediction* (p. 143-164). Elsevier. doi: <https://doi.org/10.1016/B978-0-12-811714-9.00007-3>
- Lorenz, D. J., & Hartmann, D. L. (2006). The effect of the mjo on the north american monsoon. *Journal of Climate*, 19(3), 333–343. doi: [10.1175/JCLI3684.1](https://doi.org/10.1175/JCLI3684.1)
- Lorenz, E. N. (1963). Deterministic nonperiodic flow. *Journal of Atmospheric Sciences*, 20(2), 130 - 141. doi: [10.1175/1520-0469\(1963\)020<0130:DNF>2.0.CO;2](https://doi.org/10.1175/1520-0469(1963)020<0130:DNF>2.0.CO;2)
- Lorenz, E. N. (1969). The predictability of a flow which possesses many scales of motion. *Tellus*, 21(3), 289-307. doi: <https://doi.org/10.1111/j.2153-3490.1969.tb00444.x>
- Lorenz, E. N. (1975). Climatic predictability. the physical basis of climate and climate modeling. *GARP Publication Series, Vol. 16*, 132–136.
- Lyu, Y., Zhu, S., Zhi, X., Dong, F., Zhu, C., Ji, L., & Fan, Y. (2022). Subseasonal forecasts of precipitation over maritime continent in boreal summer and the sources of predictability. *Frontiers in Earth Science*, 10. doi: [10.3389/feart.2022.970791](https://doi.org/10.3389/feart.2022.970791)
- Madden, R. A., & Julian, P. R. (1971). Detection of a 40–50 day oscillation in the zonal wind in the tropical pacific. *Journal of Atmospheric Sciences*, 28(5). doi: [10.1175/1520-0469\(1971\)028<0702:DOADOI>2.0.CO;2](https://doi.org/10.1175/1520-0469(1971)028<0702:DOADOI>2.0.CO;2)
- Madden, R. A., & Julian, P. R. (1972). Description of global-scale circulation cells in the tropics with a 40-50 day period. *J. Atmos. Sci.*, 29, 1109–1123.
- Magaña, V., Amador, J. A., & Medina, S. (1999). The midsummer drought over mexico and central america. *Journal of Climate*, 12(6), 1577–1588. doi: [10.1175/1520-0442\(1999\)012<1577:TMDOMA>2.0.CO;2](https://doi.org/10.1175/1520-0442(1999)012<1577:TMDOMA>2.0.CO;2)
- Mahmood, R., Pielke Sr., R. A., Hubbard, K. G., Niyogi, D., Dirmeyer, P. A., McAlpine, C., ... Fall, S. (2014). Land cover changes and their biogeophysical effects on climate. *International Journal of Climatology*, 34(4), 929-953. doi: <https://doi.org/10.1002/joc.3736>
- Majda, A. J., & Stechmann, S. N. (2009). A simple dynamical model with features of convective momentum transport. *Journal of the Atmospheric Sciences*, 66(2), 373 - 392. doi: [10.1175/2008JAS2805.1](https://doi.org/10.1175/2008JAS2805.1)

- Manrique-Suñén, A., Gonzalez-Reviriego, N., Torralba, V., Cortesi, N., & Doblas-Reyes, F. J. (2020). Choices in the verification of s2s forecasts and their implications for climate services. *Monthly Weather Review*, 148(10), 3995 - 4008. doi: [10.1175/MWR-D-20-0067.1](https://doi.org/10.1175/MWR-D-20-0067.1)
- Matthews, A. J. (2008). Primary and successive events in the madden–julian oscillation. *Quarterly Journal of the Royal Meteorological Society*, 134(631), 439-453. doi: <https://doi.org/10.1002/qj.224>
- Matthews, A. J., & Kiladis, G. N. (1999). The tropical–extratropical interaction between high-frequency transients and the madden–julian oscillation. *Monthly Weather Review*, 127(5), 661 - 677. doi: [10.1175/1520-0493\(1999\)127<0661:TTEIBH>2.0.CO;2](https://doi.org/10.1175/1520-0493(1999)127<0661:TTEIBH>2.0.CO;2)
- Moon, J.-Y., Wang, B., & Ha, K.-J. (2011). Enso regulation of mjo teleconnection. *Clim. Dyn.*, 37, 1133-1149. doi: [10.1007/s00382-010-0902-3](https://doi.org/10.1007/s00382-010-0902-3)
- Moron, V., Robertson, A. W., & Wang, L. (2019). Chapter 3 - weather within climate: Sub-seasonal predictability of tropical daily rainfall characteristics. En A. W. Robertson & F. Vitart (Eds.), *Sub-seasonal to seasonal prediction* (p. 47-64). Elsevier. doi: <https://doi.org/10.1016/B978-0-12-811714-9.00003-6>
- Murphy, A. H. (1988). Skill scores based on the mean square error and their relationships to the correlation coefficient. *Monthly Weather Review*, 116(12), 2417 - 2424. doi: [10.1175/1520-0493\(1988\)116<2417:SSBOTM>2.0.CO;2](https://doi.org/10.1175/1520-0493(1988)116<2417:SSBOTM>2.0.CO;2)
- Murphy, A. H., & Epstein, E. S. (1989). Skill scores and correlation coefficients in model verification. *Monthly Weather Review*, 117(3), 572 - 582. doi: [10.1175/1520-0493\(1989\)117<0572:SSACCI>2.0.CO;2](https://doi.org/10.1175/1520-0493(1989)117<0572:SSACCI>2.0.CO;2)
- Nakazawa, T. (1986). Intraseasonal variations of olr in the tropics during the fgge year. *Journal of the Meteorological Society of Japan. Ser. II*, 64, 17-34. doi: [10.2151/jmsj1965.64.1_17](https://doi.org/10.2151/jmsj1965.64.1_17)
- Olvera-Lazcano, L. (2022). *Influencia de la mjo en los eventos extremos de precipitación y su relación con la alberca de agua caliente sobre el pacífico mexicano*. (Tesis de Licenciatura, Facultad de Ciencias, Universidad Nacional Autónoma de México, Ciudad de México). Descargado de <http://132.248.9.195/ptd2022/mayo/0825130/Index.html>
- Palmer, T., & Hagedorn, R. (2006). *Predictability of weather and climate*. Cambridge University Press.
- Peixoto, J., & Oort, A. (1992). *Physics of climate*. American Institute of Physics. Descargado de <https://books.google.com.mx/books?id=3tjKa0YzFRMC>

- Peng, Y., Liu, X., Su, J., Liu, X., & Zhang, Y. (2023). Skill improvement of the yearly updated reforecasts in ecmwf s2s prediction from 2016 to 2022. *Atmospheric and Oceanic Science Letters*, 16(5), 100357. doi: <https://doi.org/10.1016/j.aosl.2023.100357>
- Perdigón-Morales, J., Romero-Centeno, R., Barrett, B. S., & Ordoñez, P. (2019). Intraseasonal variability of summer precipitation in mexico: Mjo influence on the midsummer drought. *Journal of Climate*, 32(8), 2313 - 2327. doi: [10.1175/JCLI-D-18-0425.1](https://doi.org/10.1175/JCLI-D-18-0425.1)
- Perdigón-Morales, J., Romero-Centeno, R., Ordoñez, P., Nieto, R., Gimeno, L., & Barrett, B. S. (2021). Influence of the madden-julian oscillation on moisture transport by the caribbean low level jet during the midsummer drought in mexico. *Atmospheric Research*, 248, 105243. doi: <https://doi.org/10.1016/j.atmosres.2020.105243>
- Pérez, D. (2022). *Evaluación de los productos chirps y era5 a partir de quiahua, una red de monitoreo ciudadano de precipitación en cuencas de montaña del centro de veracruz* (Tesis de Licenciatura, Facultad de Ciencias, Universidad Nacional Autónoma de México, Ciudad de México). Descargado de <http://132.248.9.195/ptd2022/octubre/0831731/Index.html>
- Ramos-Pérez, O., Adams, D. K., Ochoa-Moya, C. A., & Quintanar, A. I. (2022). A climatology of mesoscale convective systems in northwest mexico during the north american monsoon. *Atmosphere*, 13(5). doi: [10.3390/atmos13050665](https://doi.org/10.3390/atmos13050665)
- Raymond, D. J. (2001). A new model of the madden–julian oscillation. *Journal of the Atmospheric Sciences*, 58(18), 2807 - 2819. doi: [10.1175/1520-0469\(2001\)058<2807:ANMOTM>2.0.CO;2](https://doi.org/10.1175/1520-0469(2001)058<2807:ANMOTM>2.0.CO;2)
- Rossa, A., Nurmi, P., & Ebert, E. (2008). Overview of methods for the verification of quantitative precipitation forecasts. En S. Michaelides (Ed.), *Precipitation: Advances in measurement, estimation and prediction* (pp. 419–452). Berlin, Heidelberg: Springer Berlin Heidelberg. doi: [10.1007/978-3-540-77655-0_16](https://doi.org/10.1007/978-3-540-77655-0_16)
- Roxy, K. (2013). Sensitivity of precipitation to sea surface temperature over the tropical summer monsoon region—and its quantification. *Climate Dynamics*, 43. doi: [10.1007/s00382-013-1881-y](https://doi.org/10.1007/s00382-013-1881-y)
- Ruiz-Vásquez, M., O, S., Brenning, A., Koster, R. D., Balsamo, G., Weber, U., ... Orth, R. (2022). Exploring the relationship between temperature forecast errors and earth system variables. *Earth System Dynamics*, 13(4), 1451–1471. doi: [10.5194/esd-13-1451-2022](https://doi.org/10.5194/esd-13-1451-2022)
- Seo, K.-H., & Kumar, A. (2008). The onset and life span of the madden-julian oscillation. *Theoretical and Applied Climatology*, 94, 13-24. doi: [10.1007/s00704-007-0340-2](https://doi.org/10.1007/s00704-007-0340-2)
- Serra, Y. L., Jiang, X., Tian, B., Amador-Astua, J., Maloney, E. D., & Kiladis, G. N. (2014). Tropical intraseasonal modes of the atmosphere [Journal Article]. *Annual Review of Environment and*

- Resources*, 39(Volume 39, 2014), 189-215. doi: <https://doi.org/10.1146/annurev-environ-020413-134219>
- Shimizu, M. H., Ambrizzi, T., & Liebmann, B. (2017). Extreme precipitation events and their relationship with enso and mjo phases over northern south america. *International Journal of Climatology*, 37(6), 2977-2989. doi: <https://doi.org/10.1002/joc.4893>
- Slingo, J., Sperber, K., Boyle, J., Ceron, J.-P., Dix, M., Dugas, B., ... Rennó, N. (1996). Intraseasonal oscillations in 15 atmospheric general circulation models: results from an amip diagnostic subproject. *Climate Dynamics*, 12, 325-357. doi: [10.1007/BF00231106](https://doi.org/10.1007/BF00231106)
- Sobel, A., & Maloney, E. (2012). An idealized semi-empirical framework for modeling the madden-julian oscillation. *Journal of the Atmospheric Sciences*, 69(5), 1691 - 1705. doi: [10.1175/JAS-D-11-0118.1](https://doi.org/10.1175/JAS-D-11-0118.1)
- Sobel, A., Nilsson, J., & Polvani, L. (2001). The weak temperature gradient approximation and balanced tropical moisture waves. *Journal of the Atmospheric Sciences*, 58(23), 3650-3665. doi: [10.1175/1520-0469\(2001\)058<3650:TWTGAA>2.0.CO;2](https://doi.org/10.1175/1520-0469(2001)058<3650:TWTGAA>2.0.CO;2)
- Sperber, K. R. (2003). Propagation and the vertical structure of the madden-julian oscillation. *Monthly Weather Review*, 131(12), 3018-3037. doi: [10.1175/1520-0493\(2003\)131<3018:PATVSO>2.0.CO;2](https://doi.org/10.1175/1520-0493(2003)131<3018:PATVSO>2.0.CO;2)
- Stan, C., Zheng, C., Chang, E. K.-M., Domeisen, D. I. V., Garfinkel, C. I., Jenney, A. M., ... Yadav, P. (2022). Advances in the prediction of mjo teleconnections in the s2s forecast systems. *Bulletin of the American Meteorological Society*, 103(6), E1426 - E1447. doi: [10.1175/BAMS-D-21-0130.1](https://doi.org/10.1175/BAMS-D-21-0130.1)
- Stechmann, S. N., & Majda, A. J. (2015). Identifying the skeleton of the madden-julian oscillation in observational data. *Monthly Weather Review*, 143(1), 395 - 416. doi: [10.1175/MWR-D-14-00169.1](https://doi.org/10.1175/MWR-D-14-00169.1)
- Straub, K. H. (2013). Mjo initiation in the real-time multivariate mjo index. *Journal of Climate*, 26(4), 1130 - 1151. doi: [10.1175/JCLI-D-12-00074.1](https://doi.org/10.1175/JCLI-D-12-00074.1)
- Takaya, Y. (2019). Chapter 12 - forecast system design, configuration, and complexity. En A. W. Robertson & F. Vitart (Eds.), *Sub-seasonal to seasonal prediction* (p. 245-259). Elsevier. doi: <https://doi.org/10.1016/B978-0-12-811714-9.00012-7>
- Toth, Z., & Buizza, R. (2019). Chapter 2 - weather forecasting: What sets the forecast skill horizon? En A. W. Robertson & F. Vitart (Eds.), *Sub-seasonal to seasonal prediction* (p. 17-45). Elsevier. doi: <https://doi.org/10.1016/B978-0-12-811714-9.00002-4>

- Tyagi, S., Zhang, X., Saraswat, D., Sahany, S., Mishra, S. K., & Niyogi, D. (2022). Flash drought: Review of concept, prediction and the potential for machine learning, deep learning methods. *Earth's Future*, 10(11), e2022EF002723. doi: <https://doi.org/10.1029/2022EF002723>
- Vitart, F. (2004). Monthly forecasting at ecmwf. *Monthly Weather Review*, 132(12), 2761 - 2779. doi: [10.1175/MWR2826.1](https://doi.org/10.1175/MWR2826.1)
- Vitart, F., Ardilouze, C., Bonet, A., Brookshaw, A., Chen, M., Codorean, C., ... Zhang, L. (2017). The subseasonal to seasonal (s2s) prediction project database. *Bulletin of the American Meteorological Society*, 98(1), 163 - 173. doi: [10.1175/BAMS-D-16-0017.1](https://doi.org/10.1175/BAMS-D-16-0017.1)
- Vitart, F., & Balmaseda, M. A. (2024). Sources of mjo teleconnection errors in the ecmwf extended-range forecasts. *Quarterly Journal of the Royal Meteorological Society*, 150(761), 2028-2044. doi: <https://doi.org/10.1002/qj.4688>
- Vitart, F., Cunningham, C., DeFlorio, M., Dutra, E., Ferranti, L., Golding, B., ... Tippett, M. K. (2019). Chapter 17 - sub-seasonal to seasonal prediction of weather extremes. En A. W. Robertson & F. Vitart (Eds.), *Sub-seasonal to seasonal prediction* (p. 365-386). Elsevier. doi: <https://doi.org/10.1016/B978-0-12-811714-9.00017-6>
- Vitart, F., & Robertson, A. W. (2019). Chapter 1 - introduction: Why sub-seasonal to seasonal prediction (s2s)? En A. W. Robertson & F. Vitart (Eds.), *Sub-seasonal to seasonal prediction* (p. 3-15). Elsevier. doi: <https://doi.org/10.1016/B978-0-12-811714-9.00001-2>
- Wallace, J. M., & Gutzler, D. S. (1981). Teleconnections in the geopotential height field during the northern hemisphere winter. *Monthly Weather Review*, 109(4), 784-812. doi: [10.1175/1520-0493\(1981\)109<0784:TITGHF>2.0.CO;2](https://doi.org/10.1175/1520-0493(1981)109<0784:TITGHF>2.0.CO;2)
- Wang, B. (1988). Dynamics of tropical low-frequency waves: An analysis of the moist kelvin wave. *Journal of Atmospheric Sciences*, 45(14), 2051 - 2065. doi: [10.1175/1520-0469\(1988\)045<2051:DOTLFW>2.0.CO;2](https://doi.org/10.1175/1520-0469(1988)045<2051:DOTLFW>2.0.CO;2)
- Wang, B., Chen, G., & Liu, F. (2019). Diversity of the madden-julian oscillation. *Science Advances*, 5(7), eaax0220. doi: [10.1126/sciadv.aax0220](https://doi.org/10.1126/sciadv.aax0220)
- Wang, B., & Li, T. (1994). Convective interaction with boundary-layer dynamics in the development of a tropical intraseasonal system. *Journal of Atmospheric Sciences*, 51(11), 1386-1400. doi: [10.1175/1520-0469\(1994\)051<1386:CIWBLD>2.0.CO;2](https://doi.org/10.1175/1520-0469(1994)051<1386:CIWBLD>2.0.CO;2)
- Wang, B., Liu, F., & Chen, G. (2016). A trio-interaction theory for madden-julian oscillation. *Geoscience Letters*, 3. doi: [10.1186/s40562-016-0066-z](https://doi.org/10.1186/s40562-016-0066-z)
- Wang, C. (2007). Variability of the caribbean low-level jet and its relations to climate. *Climate Dynamics*, 29, 411-422. doi: [10.1007/s00382-007-0243-z](https://doi.org/10.1007/s00382-007-0243-z)

- Wang, C., & Fiedler, P. C. (2006). Enso variability and the eastern tropical pacific: A review. *Progress in Oceanography*, 69(2), 239-266. (A Review of Eastern Tropical Pacific Oceanography) doi: <https://doi.org/10.1016/j.pocean.2006.03.004>
- Wang, S., Ma, D., Sobel, A. H., & Tippett, M. K. (2018). Propagation characteristics of bsiso indices. *Geophysical Research Letters*, 45(18), 9934-9943. doi: <https://doi.org/10.1029/2018GL078321>
- Wang, S., Martin, Z. K., Sobel, A. H., Tippett, M. K., Dias, J., Kiladis, G. N., ... Wu, J. (2022). A multivariate index for tropical intraseasonal oscillations based on the seasonally-varying modal structures. *Journal of Geophysical Research: Atmospheres*, 127(4), e2021JD035961. doi: <https://doi.org/10.1029/2021JD035961>
- Wang, S., & Sobel, A. H. (2022). A unified moisture mode theory for the madden–julian oscillation and the boreal summer intraseasonal oscillation. *Journal of Climate*, 35(4), 1267 - 1291. doi: [10.1175/JCLI-D-21-0361.1](https://doi.org/10.1175/JCLI-D-21-0361.1)
- Wei, Y., Ren, H.-L., Xiang, B., Wang, Y., Wu, J., & Wang, S. (2023). Diverse mjo genesis and predictability. *Bulletin of the American Meteorological Society*, 104(4), E792 - E809. doi: [10.1175/BAMS-D-22-0101.1](https://doi.org/10.1175/BAMS-D-22-0101.1)
- Weidman, S., Kleiner, N., & Kuang, Z. (2022). A rotation procedure to improve seasonally varying empirical orthogonal function bases for mjo indices. *Geophysical Research Letters*, 49(15), e2022GL099998. doi: <https://doi.org/10.1029/2022GL099998>
- Wheeler, M., & Hendon, H. H. (2004). An all-season real-time multivariate mjo index: Development of an index for monitoring and prediction. *Monthly Weather Review*, 132(8), 1917–1932. doi: [10.1175/1520-0493\(2004\)132<1917:AARMMI>2.0.CO;2](https://doi.org/10.1175/1520-0493(2004)132<1917:AARMMI>2.0.CO;2)
- White, C. J., Carlsen, H., Robertson, A. W., Klein, R. J., Lazo, J. K., Kumar, A., ... Zebiak, S. E. (2017). Potential applications of subseasonal-to-seasonal (s2s) predictions. *Meteorological Applications*, 24(3), 315-325. doi: <https://doi.org/10.1002/met.1654>
- Wilks, D. S. (2019). Chapter 5 - frequentist statistical inference. En D. S. Wilks (Ed.), *Statistical methods in the atmospheric sciences (fourth edition)* (Fourth Edition ed., p. 143-207). Elsevier. doi: <https://doi.org/10.1016/B978-0-12-815823-4.00005-5>
- Woolnough, S. J. (2019). Chapter 5 - the madden-julian oscillation. En A. W. Robertson & F. Vitart (Eds.), *Sub-seasonal to seasonal prediction* (p. 93-117). Elsevier. doi: <https://doi.org/10.1016/B978-0-12-811714-9.00005-X>
- Wu, J., Ren, H., Jia, X., & Zhang, P. (2023). Climatological diagnostics and subseasonal-to-seasonal predictions of madden–julian oscillation events. *International Journal of Climatology*, 43. doi: [10.1002/joc.7984](https://doi.org/10.1002/joc.7984)

- Wulff, C. O., Vitart, F., & Domeisen, D. I. V. (2022). Influence of trends on subseasonal temperature prediction skill. *Quarterly Journal of the Royal Meteorological Society*, 148(744), 1280-1299. doi: <https://doi.org/10.1002/qj.4259>
- Yadav, P., Garfinkel, C. I., & Domeisen, D. I. V. (2024). The role of the stratosphere in teleconnections arising from fast and slow mjo episodes. *Geophysical Research Letters*, 51(1), e2023GL104826. doi: <https://doi.org/10.1029/2023GL104826>
- Yadav, P., & Straus, D. M. (2017). Circulation response to fast and slow mjo episodes. *Monthly Weather Review*, 145(5), 1577 - 1596. doi: [10.1175/MWR-D-16-0352.1](https://doi.org/10.1175/MWR-D-16-0352.1)
- Yang, D., & Ingersoll, A. P. (2014). A theory of the mjo horizontal scale. *Geophysical Research Letters*, 41(3), 1059-1064. doi: <https://doi.org/10.1002/2013GL058542>
- Yano, J.-I., & Tribbia, J. J. (2017). Tropical atmospheric madden–julian oscillation: A strongly nonlinear free solitary rossby wave? *Journal of the Atmospheric Sciences*, 74(10), 3473-3489. doi: [10.1175/JAS-D-16-0319.1](https://doi.org/10.1175/JAS-D-16-0319.1)
- Zeng, L., Bao, Q., Wu, X., He, B., Yang, J., Wang, T., ... Liu, Y. (2023). Impacts of humidity initialization on mjo prediction: A study in an operational sub-seasonal to seasonal system. *Atmospheric Research*, 294, 106946. doi: <https://doi.org/10.1016/j.atmosres.2023.106946>
- Zhang, C. (2013). Madden-julian oscillation: Bridging weather and climate. *Bulletin of the American Meteorological Society*, 94(12), 1849–1870. doi: [10.1175/BAMS-D-12-00026.1](https://doi.org/10.1175/BAMS-D-12-00026.1)
- Zhang, C., & Gottschalck, J. (2002). Sst anomalies of enso and the madden-julian oscillation in the equatorial pacific. *Journal of Climate*, 15(17), 2429–2445. doi: [10.1175/1520-0442\(2002\)015<2429:SAOEAT>2.0.CO;2](https://doi.org/10.1175/1520-0442(2002)015<2429:SAOEAT>2.0.CO;2)
- Zhang, H. (2020). Tropical pacific intensifies june extreme rainfall over southwestern united states/northwestern mexico. *Climate Dynamics*, 55. doi: [10.1007/s00382-020-05291-6](https://doi.org/10.1007/s00382-020-05291-6)
- Zhao, Z., Han, M., Yang, K., & Holbrook, N. J. (2023). Signatures of midsummer droughts over Central America and Mexico. *Climate Dynamics*, 60(11-12), 3523-3542. doi: [10.1007/s00382-022-06505-9](https://doi.org/10.1007/s00382-022-06505-9)